

ĐẠI HỌC BÁCH KHOA HÀ NỘI
KHOA TOÁN TIN



**Phân tích cấu trúc dữ liệu nhiều chiều và
xây dựng mô hình phân tích thành phần chính**

MÔN PHÂN TÍCH SỐ LIỆU

Chuyên ngành: Toán tin

Giảng viên hướng dẫn: PGS. TS. Nguyễn Thị Ngọc Anh

Học viên thực hiện: Vũ Mạnh Tiền 20251084M

Đinh Văn Tùng 20252876M

HÀ NỘI, 05/2026

Mục lục

Danh sách bảng	1
Danh sách hình vẽ	2
Mở đầu	3
Chương 1 Giới thiệu bài toán	5
Chương 2 Mô tả và phân tích dữ liệu nhiều chiều	7
2.1 Bộ dữ liệu "Ước lượng mức độ béo phì dựa trên thói quen ăn uống và tình trạng thể chất"	7
2.1.1 Mô tả dữ liệu	7
2.1.2 Phân tích dữ liệu nhiều chiều	10
2.1.3 Bộ dữ liệu MNIST	16
2.1.4 Bộ dữ liệu CIFAR-10	17
Chương 3 Phản biện giả thiết và phân tích hình học dữ liệu	19
3.1 Giả thiết dữ liệu có thể được xấp xỉ bởi phân phối chuẩn nhiều chiều .	19
3.2 Khoảng cách Euclidean và khoảng cách Mahalanobis	20
3.3 Kiểm tra một số giả thiết sai	21
Chương 4 Pipeline xử lý dữ liệu	23
4.1 Các thành phần chính của Pipeline	24
4.1.1 Tách tập huấn luyện và tập kiểm tra (Train-Test Split)	24
4.1.2 Xử lý nhãn (Labels Separation)	26
4.1.3 Xử lý dữ liệu thiếu (Handle Missing Values)	28
4.1.4 Mã hóa dữ liệu (Data Encoding)	30
4.1.5 Chuẩn hóa đặc trưng (Standardize Feature)	31
4.1.6 Loại bỏ biến có phương sai thấp (Remove Low Variance)	32
4.1.7 Phát hiện và loại bỏ ngoại lai (Outlier Detection)	33
4.1.8 Kết quả đầu ra (Processed Train Set và Processed Test Set) . .	35

4.1.9 Tổng kết pipeline	36
Chương 5 Mô hình nâng cao đề xuất	37
5.1 Giới thiệu	37
5.2 Cơ sở toán học của PCA	38
5.3 Các thành phần chính thu được từ các biến đã được chuẩn hóa	41
5.4 Tổng hợp biến thiên mẫu bằng các thành phần chính	42
Chương 6 Cài đặt thử nghiệm	45
6.1 Tập dữ liệu béo phì	47
6.2 Tập MNIST	51
6.3 Tập CIFAR-10	53
Hạn chế và kết luận	56
Tài liệu tham khảo	57
Phụ lục minh bạch AI	58

Danh sách bảng

2.1	Bảng mô tả dữ liệu	9
2.2	Giá trị trung bình của các biến	11
2.3	Ma trận hiệp phương sai nhóm nhân trắc học	13
2.4	Ma trận hệ số tương quan mẫu nhóm nhân trắc học	13
2.5	Ma trận hiệp phương sai mẫu nhóm thói quen dinh dưỡng	13
2.6	Ma trận hệ số tương quan mẫu nhóm thói quen dinh dưỡng	14
2.7	Ma trận hiệp phương sai mẫu của nhóm lối sống và hoạt động thể chất	14
2.8	Ma trận tương quan mẫu của nhóm lối sống và hoạt động thể chất	14
2.9	Hệ số tương quan giữa các biến và mức độ béo phì	15
6.1	Kết quả PCA trên tập dữ liệu MNIST	52
6.2	Kết quả PCA và đánh giá mô hình trên tập dữ liệu CIFAR-10	54

Danh sách hình vẽ

2.1	Phân bố không cân bằng về mức độ béo phì trong tập dữ liệu gốc. . . .	8
2.2	Phân bố cân bằng về mức độ béo phì (sau khi SMOTE [3]).	8
2.3	Ví dụ về ảnh MNIST	17
2.4	Ví dụ về ảnh CIFAR-10	18
4.1	Pipeline xử lý dữ liệu	24
6.1	Bảng tóm tắt PCA	47
6.2	Enter Caption	48
6.3	Metrics PCA	49
6.4	PCA vs non-PCA với Logistic Regression của tập dữ liệu béo phì . . .	50
6.5	PCA vs non-PCA với Logistic Regression của tập MNIST	52
6.6	PCA vs non-PCA với Logistic Regression của tập CIFAR-10	54

Mở đầu

Trong bối cảnh chuyển đổi số và sự phát triển mạnh mẽ của công nghệ dữ liệu, lĩnh vực y tế và chăm sóc sức khỏe đang tạo ra khối lượng lớn dữ liệu đa dạng từ hồ sơ bệnh án điện tử, kết quả xét nghiệm, dữ liệu hình ảnh y khoa, thông tin di truyền học đến dữ liệu theo dõi sức khỏe cá nhân. Khối lượng dữ liệu lớn cùng nhiều biến số liên quan đặt ra yêu cầu cần có các phương pháp phân tích phù hợp nhằm khai thác thông tin hữu ích, hỗ trợ quá trình dự đoán, chẩn đoán và đưa ra quyết định trong chăm sóc sức khỏe. Vì vậy, môn học Phân tích số liệu đóng vai trò quan trọng trong việc trang bị nền tảng lý thuyết và kỹ năng xử lý, phân tích dữ liệu phục vụ nghiên cứu cũng như ứng dụng thực tiễn.

Phân tích số liệu là quá trình sử dụng các phương pháp thống kê, toán học và kỹ thuật tính toán để khám phá quy luật, xu hướng và mối quan hệ giữa các biến trong tập dữ liệu. Trong nghiên cứu hiện đại, đặc biệt ở lĩnh vực y tế, dữ liệu thường tồn tại dưới dạng đa chiều với số lượng lớn biến quan sát. Việc phân tích cấu trúc dữ liệu nhiều chiều giúp nhận diện đặc điểm phân bố dữ liệu, đánh giá mối liên hệ giữa các yếu tố và hỗ trợ giảm độ phức tạp của dữ liệu mà vẫn giữ được phần lớn thông tin quan trọng.

Một trong những phương pháp phổ biến để xử lý dữ liệu nhiều chiều là Phân tích thành phần chính (Principal Component Analysis – PCA). PCA là kỹ thuật giảm chiều dữ liệu thông qua việc chuyển đổi tập hợp nhiều biến tương quan thành một số lượng nhỏ các thành phần chính không tương quan, đồng thời bảo toàn tối đa phương sai của dữ liệu gốc. Trong lĩnh vực y tế và chăm sóc sức khỏe, PCA được ứng dụng rộng rãi trong phân tích dữ liệu bệnh nhân, phát hiện yếu tố nguy cơ bệnh lý, phân loại nhóm bệnh, xử lý dữ liệu gene, cũng như hỗ trợ xây dựng các mô hình dự báo và hệ thống hỗ trợ quyết định lâm sàng.

Việc nghiên cứu phân tích cấu trúc dữ liệu nhiều chiều và xây dựng mô hình phân tích thành phần chính có ý nghĩa quan trọng trong việc nâng cao khả năng xử lý dữ

liệu phức tạp, tối ưu hóa mô hình dự báo và cải thiện hiệu quả khai thác thông tin trong y tế. Đồng thời, các phương pháp này góp phần hỗ trợ các chuyên gia y tế đưa ra quyết định nhanh chóng và chính xác hơn, từ đó nâng cao chất lượng chăm sóc sức khỏe cộng đồng.

Trên cơ sở đó, báo cáo này tập trung tìm hiểu cơ sở lý thuyết của phân tích dữ liệu nhiều chiều, nguyên lý hoạt động của mô hình PCA và ứng dụng của phương pháp này trong lĩnh vực y tế, nhằm đánh giá khả năng giảm chiều dữ liệu và hỗ trợ phân tích thông tin phục vụ chăm sóc sức khỏe.

Chương 1

Giới thiệu bài toán

Trong bối cảnh chuyển đổi lối sống hiện đại, béo phì đã không còn đơn thuần là một vấn đề thẩm mỹ mà đã trở thành một trong những vấn đề sức khỏe cộng đồng nghiêm trọng trên toàn thế giới. Theo báo cáo mới nhất của Tổ chức Y tế Thế giới (World Health Organization [WHO], 2025) [1], ước tính vào năm 2022, cứ 8 người trên thế giới thì có 1 người đang sống chung với bệnh béo phì. Quy mô của cuộc khủng hoảng này được thể hiện qua con số 2,5 tỷ người trưởng thành bị thừa cân, trong đó có 890 triệu người đã chuyển sang giai đoạn béo phì lâm sàng. Đáng lo ngại hơn, tỷ lệ béo phì ở người trưởng thành đã tăng gấp đôi kể từ năm 1990, trong khi con số này ở thanh thiếu niên đã tăng gấp bốn lần, tạo nên một áp lực khổng lồ lên hệ thống y tế toàn cầu.

Sự gia tăng phi mã này không chỉ dừng lại ở nhóm tuổi trưởng thành mà đang xâm lấn mạnh mẽ vào thế hệ tương lai. Số liệu năm 2024 cho thấy có 35 triệu trẻ em dưới 5 tuổi bị thừa cân và hơn 390 triệu trẻ em cũng như thanh thiếu niên (từ 5–19 tuổi) đang đối mặt với tình trạng tương tự. Những con số này là minh chứng cho sự thất bại trong việc kiểm soát các yếu tố rủi ro cốt lõi, đặc biệt là thói quen ăn uống và điều kiện thể chất. Việc hiểu rõ cách thức thói quen sinh hoạt tác động đến mức độ béo phì hiện nay là yêu cầu cấp bách để ngăn chặn các biến chứng nguy hiểm như tiểu đường, tim mạch, huyết áp cao và rối loạn chuyển hóa ngay từ giai đoạn sớm.

Trong bối cảnh đó, ý nghĩa của việc phân tích số liệu trong y tế trở nên quan trọng hơn bao giờ hết. Y tế hiện đại không chỉ dừng lại ở việc điều trị mà đang chuyển dịch mạnh mẽ sang y tế dự phòng và quản lý dữ liệu. Việc ứng dụng các kỹ thuật phân tích đa biến để ước lượng mức độ béo phì dựa trên thói quen ăn uống và tình trạng thể chất cho phép các nhà hoạch định chính sách và bác sĩ lâm sàng nhìn thấu "cấu trúc

hành vi" của bệnh nhân. Thay vì chỉ dựa vào các phép đo đơn lẻ, việc phân tích dữ liệu giúp xây dựng các mô hình dự báo chính xác, từ đó đưa ra các can thiệp kịp thời và cá nhân hóa. Nghiên cứu này, thông qua việc phân tích chuyên sâu các chỉ số sức khỏe, hướng tới mục tiêu cung cấp một công cụ ước lượng khoa học, góp phần giảm thiểu gánh nặng bệnh tật dựa trên những bằng chứng số liệu xác thực và khách quan.


Chương 2

Mô tả và phân tích dữ liệu nhiều chiều


2.1 Bộ dữ liệu "Ước lượng mức độ béo phì dựa trên thói quen ăn uống và tình trạng thể chất"

2.1.1 Mô tả dữ liệu

Bộ dữ liệu nghiên cứu về việc ước lượng mức độ béo phì dựa trên thói quen ăn uống và tình trạng thể chất được sử dụng trong phân tích này cung cấp cái nhìn chi tiết về các chỉ số sức khỏe của các cá nhân tại ba quốc gia khu vực Mỹ Latinh bao gồm Mexico, Peru và Colombia [2]. Tổng cộng có 2.111 bản ghi được thu thập, phản ánh các đặc trưng đa dạng thông qua 17 thuộc tính biến số. Một đặc điểm quan trọng về phương pháp luận của bộ dữ liệu này là sự kết hợp giữa dữ liệu thực và dữ liệu tổng hợp: trong đó 23% dữ liệu được thu thập trực tiếp từ người dùng thông qua các nền tảng trực tuyến, và 77% dữ liệu còn lại được tạo ra bằng phương pháp tổng hợp thông qua công cụ Weka và bộ lọc SMOTE [3] nhằm đảm bảo sự cân bằng giữa các nhóm phân loại như trong Hình 2.1 và 2.2.



Hình 2.1: Phân bố không cân bằng về mức độ béo phì trong tập dữ liệu gốc.



Hình 2.2: Phân bố cân bằng về mức độ béo phì (sau khi SMOTE [3]).

Hệ thống các thuộc tính trong nghiên cứu được phân chia thành ba nhóm cốt lõi. Nhóm các biến về thói quen ăn uống bao gồm: tiêu thụ thực phẩm giàu calo (FAVC), tần suất ăn rau củ quả (FCVC), số lượng bữa ăn chính (NCP), ăn vặt giữa các bữa (CAEC), lượng nước uống hàng ngày (CH2O) và mức độ tiêu thụ rượu bia (CALC). Nhóm các biến về tình trạng thể chất và lối sống bao gồm: theo dõi lượng calo (SCC), tần suất vận động (FAF), thời gian sử dụng thiết bị công nghệ (TUE), phương tiện di chuyển thường xuyên (MTRANS) và tình trạng hút thuốc (SMOKE). Bên cạnh đó, các biến nhân khẩu học và sinh trắc học cơ bản như giới tính, tuổi, chiều cao và cân nặng cũng được ghi nhận để làm cơ sở tính toán. Đặc biệt, nghiên cứu còn tích hợp yếu tố di truyền và môi trường gia đình thông qua biến số ghi nhận liệu cá nhân có thành viên gia đình từng bị thừa cân hay không (family_history_with_overweight).

Biến mục tiêu cốt lõi của nghiên cứu là mức độ béo phì (NOBeyesdad). Biến này phân loại tình trạng thể trạng của các đối tượng thành bảy danh mục phân biệt: Cân nặng thiếu, Cân nặng bình thường, Thừa cân (Loại I và II), và Béo phì (Loại I, II và

III). Việc phân chia chi tiết này cho phép thực hiện các phân tích sâu hơn về mức độ ảnh hưởng của thói quen ăn uống cũng như thể chất và lối sống đối với từng giai đoạn phát triển của bệnh lý béo phì. Xem thêm mô tả tại Bảng 2.1.

Tên biến	Loại biến	Mô tả
Gender	Phân loại	Giới tính sinh học của cá nhân (nam hoặc nữ).
Age	Liên tục	Số tuổi của cá nhân.
Height	Liên tục	Chiều cao của cá nhân.
Weight	Liên tục	Cân nặng của cá nhân.
family_history_with_overweight	Nhị phân	Cá nhân có thành viên gia đình bị thừa cân hoặc béo phì hay không?
FAVC	Nhị phân	Cá nhân có thường xuyên ăn thực phẩm giàu calo hay không?
FCVC	Số nguyên	Mức độ thường xuyên ăn rau (1 = không bao giờ, 2 = thỉnh thoảng, 3 = luôn luôn).
NCP	Liên tục	Số lượng bữa ăn chính (1 = từ 1 đến 2 bữa, 2 = ba bữa, 3 = nhiều hơn ba bữa).
CAEC	Phân loại	Mức độ thường xuyên ăn vặt giữa các bữa (1 = không, 2 = thỉnh thoảng, 3 = thường xuyên, 4 = luôn luôn).
SMOKE	Nhị phân	Cá nhân có hút thuốc hay không?
CH2O	Liên tục	Lượng nước cá nhân uống mỗi ngày (1 = ít hơn 1 lít, 2 = từ 1 đến 2 lít, 3 = nhiều hơn 2 lít).
SCC	Nhị phân	Cá nhân có kiểm soát lượng calo nạp vào hay không?
FAF	Liên tục	Mức độ thường xuyên hoạt động thể chất của cá nhân (1 = không bao giờ, 2 = 1 đến 2 lần/tuần, 3 = 2 đến 4 lần/tuần, 4 = 4 đến 5 lần/tuần).
TUE	Số nguyên	Thời gian sử dụng các thiết bị điện tử (0 = 0-2 giờ/ngày, 1 = 3-5 giờ/ngày, 2 = nhiều hơn 5 giờ).
CALC	Phân loại	Mức độ thường xuyên uống rượu bia (1 = không uống, 2 = thỉnh thoảng, 3 = thường xuyên, 4 = luôn luôn).
MTRANS	Phân loại	Loại phương tiện thường sử dụng (ô tô, xe máy, xe đạp, phương tiện công cộng, đi bộ).
NObesdad	Phân loại	Mức độ béo phì

Bảng 2.1: Bảng mô tả dữ liệu

Giá trị khoa học và thực tiễn của bộ dữ liệu nằm ở khả năng hỗ trợ đa dạng các nhiệm vụ khai phá dữ liệu như phân loại, dự báo, phân cụm và liên kết. Với cấu trúc dữ liệu đa vùng miền, tập dữ liệu này cho phép xây dựng các công cụ tính toán thông minh và hệ thống khuyến nghị nhằm giám sát sức khỏe cá nhân một cách tự động. Đồng thời, thông qua việc phân tích các thuộc tính về thói quen dinh dưỡng và vận động, dữ liệu cung cấp bằng chứng thực nghiệm để kiểm chứng và xác định các tác nhân chính thúc đẩy sự gia tăng tỷ lệ béo phì trong cộng đồng. Đây là cơ sở dữ liệu quan trọng để phát triển các giải pháp phần mềm hiện đại hướng tới việc cá nhân hóa quá trình quản lý và phòng ngừa các rủi ro liên quan đến thừa cân.

2.1.2 Phân tích dữ liệu nhiều chiều

Để có cái nhìn tổng quan về các đặc trưng thống kê của bộ dữ liệu, trước hết ta xem mỗi quan sát như một véc-tơ ngẫu nhiên đa chiều:

$$\mathbf{X} = (X_1, X_2, \dots, X_{17})^T$$

Véc-tơ trung bình mẫu $\bar{x}$ thể hiện giá trị trung bình của các đối tượng tham gia nghiên cứu. Công thức trung bình mẫu cho mỗi biến được xác định từ n phép đo trong p biến như sau [4]:

$$\bar{x}_k = \frac{1}{n} \sum_{j=1}^n x_{jk}, \quad k = 1, 2, \dots, p.$$

Dựa trên công thức này, các giá trị trung bình cụ thể cho 17 thuộc tính của bộ dữ liệu béo phì được tổng hợp tại Bảng 2.2.

Biến	Giá trị trung bình
Gender	0.494
Age	24.313
Height	1.702
Weight	86.586
family_history_with_overweight	0.818
FAVC	0.884
FCVC	2.419
NCP	2.686
CAEC	1.859
SMOKE	0.021
CH2O	2.008
SCC	0.045
FAF	1.010
TUE	0.658
CALC	2.269
MTRANS	2.365
NObeyesdad	3.112

Bảng 2.2: Giá trị trung bình của các biến

Từ kết quả tính toán tại Bảng 2.2, ta có thể rút ra những nhận định quan trọng về đặc điểm mẫu nghiên cứu thông qua ba nhóm chỉ số chính: đặc điểm nhân trắc học; tiểu sử và thói quen ăn uống; hoạt động thể chất và lối sống.

Trước hết, về đặc điểm nhân khẩu học, mẫu nghiên cứu thể hiện sự cân bằng về giới tính với giá trị trung bình của **Gender** đạt xấp xỉ 0,5. Đối tượng tham gia chủ yếu thuộc nhóm người trẻ tuổi với độ tuổi trung bình khoảng 24,31. Đáng chú ý, khi đối chiếu giữa chiều cao trung bình (1,702 m) và cân nặng trung bình (86,586 kg), có thể nhận thấy một bộ phận lớn cá nhân đang nằm trong ngưỡng nguy cơ về thừa cân. Điều này được minh chứng cụ thể qua biến mục tiêu **NObeyesdad** có giá trị trung bình là (3,016), phản ánh tình trạng béo phì mức độ nhẹ là đặc trưng phổ biến trong mẫu.

Tiếp tục xem xét các yếu tố rủi ro liên quan đến tiền sử gia đình và dinh dưỡng, kết quả cho thấy một mối liên hệ mật thiết giữa di truyền và béo phì. Với chỉ số **family_history_with_overweight** đạt 0,818, phần lớn người tham gia đều sống trong môi trường gia đình có tiền sử thừa cân. Yếu tố này càng trở nên trầm trọng hơn khi kết hợp với thói quen ăn uống thiếu lành mạnh: đa số đối tượng thường xuyên tiêu thụ thực phẩm giàu calo (**FAVC**=0,884) và có xu hướng ăn vặt thường xuyên (**CAEC**=1,859). Mặc dù tần suất tiêu thụ rau quả (**FCVC**=2,419) và lượng nước uống hàng ngày (**CH2O**=2,008) ở mức tương đối hợp lý, nhưng vẫn chưa đủ để bù đắp cho sự dư thừa năng lượng từ

thói quen ăn uống chính.

Cuối cùng, bức tranh về béo phì được hoàn thiện thông qua các chỉ số lối sống và hoạt động thể chất. Một tín hiệu lạc quan là tỷ lệ hút thuốc (SMOKE) trong nhóm nghiên cứu cực kỳ thấp 0,021. Tuy nhiên, tính chủ động trong việc quản lý sức khỏe vẫn còn hạn chế khi chỉ số theo dõi calo (SCC) chỉ đạt 0,045. Đặc biệt, mức độ hoạt động thể chất (FAF) chỉ dừng lại ở con số 1,01, cho thấy lối sống ít vận động là một thực trạng phổ biến. Trong khi đó, biến MTRANS đạt giá trị trung bình 2,365, phản ánh sự đa dạng trong phương tiện di chuyển của người tham gia nghiên cứu.

Tiếp nối việc xác định các giá trị trung bình thông qua véc-tơ trung bình, một khía cạnh quan trọng không kém trong phân tích đa biến là xem xét độ phân tán và mối quan hệ tương hỗ giữa các biến số. Đại lượng đầu tiên được sử dụng cho mục đích này là hiệp phương sai mẫu, được xác định bởi công thức:

$$s_{ik} = \frac{1}{n} \sum_{j=1}^n (x_{ji} - \bar{x}_i)(x_{jk} - \bar{x}_k), \quad i = 1, 2, \dots, p, \quad k = 1, 2, \dots, p.$$

Chỉ số này đo lường mức độ biến thiên cùng nhau của hai biến số bất kỳ. Khi $i = k$, hiệp phương sai trở thành phương sai mẫu (s_{ii}), phản ánh mức độ phân tán của chính biến đó xung quanh giá trị trung bình. Do có tính đối xứng ($s_{ik} = s_{ki}$), hiệp phương sai cung cấp cái nhìn sơ bộ về sự đồng biến hoặc nghịch biến của các cặp biến.

Thông kê mô tả cuối cùng được xét ở đây là hệ số tương quan mẫu. Đại lượng này đo lường mối quan hệ tuyến tính giữa hai biến và không phụ thuộc vào đơn vị đo lường. Hệ số tương quan mẫu giữa biến thứ i và biến thứ k được xác định bởi:

$$r_{ik} = \frac{s_{ik}}{\sqrt{s_{ii}}\sqrt{s_{kk}}} = \frac{\sum_{j=1}^n (x_{ji} - \bar{x}_i)(x_{jk} - \bar{x}_k)}{\sqrt{\sum_{j=1}^n (x_{ji} - \bar{x}_i)^2} \sqrt{\sum_{j=1}^n (x_{jk} - \bar{x}_k)^2}}$$

với $i, k = 1, 2, \dots, p$ và $r_{ik} = r_{ki}$ đối với mọi i và k [4].

Phân tích đa biến đòi hỏi sự hiểu biết sâu sắc về độ phân tán và cấu trúc liên kết nội tại giữa các thuộc tính. Dưới đây là các phân tích chi tiết cho từng nhóm biến đặc trưng của bộ dữ liệu dựa vào các công thức trên.

	Gender	Age	Height	Weight
Gender	0.250	-0.154	-0.029	-2.117
Age	-0.154	40.271	-0.015	33.667
Height	-0.029	-0.015	0.009	1.132
Weight	-2.117	33.667	1.132	685.977

Bảng 2.3: Ma trận hiệp phương sai nhóm nhân trắc học

	Gender	Age	Height	Weight
Gender	1.000	-0.048	-0.618	-0.162
Age	-0.048	1.000	-0.026	0.203
Height	-0.618	-0.026	1.000	0.463
Weight	-0.162	0.203	0.463	1.000

Bảng 2.4: Ma trận hệ số tương quan mẫu nhóm nhân trắc học

Phân tích nhóm biến nhân trắc học cho thấy sự khác biệt rõ rệt về quy mô biến thiên và cường độ liên kết sinh học. Về độ phân tán, quan sát đường chéo chính của ma trận hiệp phương sai (Bảng 2.3), biến **Weight** thể hiện mức độ phân tán cực kỳ lớn với phương sai $s^2 = 685,977$. Điều này phản ánh sự đa dạng về thể trạng của mẫu khảo sát, từ các cá nhân nhẹ cân đến các trường hợp béo phì mức độ cao. Ngược lại, biến **Height** có phương sai rất thấp (0,009), cho thấy chiều cao của các đối tượng trong mẫu khá đồng nhất và ít có sự đột biến. Về mối tương quan, kết quả tại Bảng 2.4 chỉ ra rằng cặp biến có tương quan mạnh nhất là **Gender** và **Height** với hệ số $r = 0,618$. Đây là một tương quan thuận mức độ lớn, phù hợp với các đặc điểm sinh học nhân trắc học thông thường. Cặp biến **Height** và **Weight** có tương quan thuận mức độ trung bình ($r = 0,463$), cho thấy xu hướng người cao hơn thường có trọng lượng lớn hơn, tuy nhiên mối quan hệ này không mang tính tuyệt đối do chịu ảnh hưởng từ các yếu tố lối sống.

	FAVC	FCVC	NCP	CAEC	CH2O	CALC
FAVC	0.103	-0.005	-0.002	0.023	0.002	-0.015
FCVC	-0.005	0.285	0.018	-0.014	0.022	-0.017
NCP	-0.002	0.018	0.605	-0.036	0.027	-0.029
CAEC	0.023	-0.014	-0.036	0.220	0.042	-0.011
CH2O	0.002	0.022	0.027	0.042	0.376	-0.029
CALC	-0.015	-0.017	-0.029	-0.011	-0.029	0.266

Bảng 2.5: Ma trận hiệp phương sai mẫu nhóm thói quen dinh dưỡng

	FAVC	FCVC	NCP	CAEC	CH2O	CALC
FAVC	1.000	-0.027	-0.007	0.150	0.010	-0.090
FCVC	-0.027	1.000	0.042	-0.055	0.068	-0.061
NCP	-0.007	0.042	1.000	-0.098	0.057	-0.072
CAEC	0.150	-0.055	-0.098	1.000	0.145	-0.048
CH2O	0.010	0.068	0.057	0.145	1.000	-0.091
CALC	-0.090	-0.061	-0.072	-0.048	-0.091	1.000

Bảng 2.6: Ma trận hệ số tương quan mẫu nhóm thói quen dinh dưỡng

Nhóm biến thói quen dinh dưỡng cung cấp cái nhìn về cấu trúc hành vi ăn uống của các đối tượng. Về độ phân tán, phương sai của các biến nhóm dinh dưỡng (Bảng 2.5) tương đối thấp và ổn định, dao động chủ yếu quanh biến số bữa ăn chính (NCP) với $s^2 = 0,605$ và lượng nước uống (CH2O) với $s^2 = 0,376$. Điều này cho thấy thói quen về số bữa ăn và lượng nước uống hàng ngày có sự biến thiên đáng kể hơn so với việc tiêu thụ thực phẩm giàu calo (FAVC). Về mối tương quan, nhìn chung, các biến trong nhóm dinh dưỡng có tương quan tuyến tính khá yếu (Bảng 2.6). Các hệ số tương quan đa số gần bằng 0 gợi ý rằng quan hệ giữa các hành vi dinh dưỡng có thể mang tính chất phi tuyến phức tạp. Chúng tỏ rằng, các thói quen ăn uống không tồn tại dưới dạng một cụm hành vi thống nhất mà biểu hiện khá độc lập ở từng cá nhân.

	FAF	TUE	SMOKE	SCC	MTRANS
FAF	0.724	0.030	0.001	0.013	0.007
TUE	0.030	0.371	0.002	-0.001	0.136
SMOKE	0.001	0.002	0.020	0.001	-0.002
SCC	0.013	-0.001	0.001	0.043	0.011
MTRANS	0.007	0.136	-0.002	0.011	1.591

Bảng 2.7: Ma trận hiệp phương sai mẫu của nhóm lối sống và hoạt động thể chất

	FAF	TUE	SMOKE	SCC	MTRANS
FAF	1.000	0.059	0.011	0.074	0.006
TUE	0.059	1.000	0.018	-0.011	0.177
SMOKE	0.011	0.018	1.000	0.048	-0.011
SCC	0.074	-0.011	0.048	1.000	0.043
MTRANS	0.006	0.177	-0.011	0.043	1.000

Bảng 2.8: Ma trận tương quan mẫu của nhóm lối sống và hoạt động thể chất

Nhóm biến lối sống phản ánh mức độ năng động và các thói quen sinh hoạt hàng ngày. Về độ phân tán, phương tiện di chuyển có độ phân tán cao nhất nhóm ($s^2 = 1,591$),

phản ánh sự khác biệt lớn trong cách thức di chuyển của các cá nhân (từ đi bộ đến sử dụng phương tiện cơ giới). Tần suất hoạt động thể chất (FAF) cũng có phương sai đáng kể (0,724), cho thấy mức độ rèn luyện thân thể có sự phân hóa rõ rệt trong mẫu. Ngược lại, việc hút thuốc có phương sai cực thấp (0,02), xác nhận tình trạng không hút thuốc là đặc điểm chung của đại đa số đối tượng khảo sát. Về mối tương quan, Bảng 2.8 cho thấy một mối liên hệ thuận nhẹ giữa thời gian sử dụng công nghệ và phương tiện di chuyển với $r = 0,177$. Điều này có thể phản ánh lối sống tĩnh tại khi việc sử dụng công nghệ nhiều thường đi kèm với việc ưu tiên các phương tiện di chuyển cơ giới thay vì vận động. Ngoài ra, mối tương quan giữa tần suất hoạt động thể chất và việc theo dõi lượng calo (SCC) là rất thấp ($r = 0,074$), cho thấy những người tập thể dục nhiều không nhất thiết là những người có thói quen kiểm soát calo nghiêm ngặt.

Biến	NObeyesdad
NObeyesdad	1.000
Weight	0.913
family_history_with_overweight	0.505
CAEC	0.329
Age	0.283
FAVC	0.248
FCVC	0.228
Height	0.134
CH2O	0.133
Gender	0.031
NCP	0.027
MTRANS	0.012
SMOKE	0.003
TUE	-0.108
CALC	-0.152
SCC	-0.195
FAF	-0.200

Bảng 2.9: Hệ số tương quan giữa các biến và mức độ béo phì

Để xác định các nhân tố đóng vai trò quyết định đối với thể trạng của các cá nhân, việc phân tích mối tương quan trực tiếp giữa các biến độc lập và biến mục tiêu là bước đi không thể thiếu. Kết quả trích xuất hệ số tương quan từ ma trận tổng thể được sắp xếp theo thứ tự giảm dần và trình bày cụ thể tại Bảng 2.9. Từ đây, ta có thể phân loại các nhân tố ảnh hưởng đến mức độ béo phì thành hai nhóm tác động rõ rệt: nhóm nhân tố nguy cơ (tương quan thuận) và nhóm nhân tố bảo vệ (tương quan nghịch).

Nhóm các nhân tố nguy cơ hàng đầu (tương quan thuận): Cân nặng là biến số có tương quan thuận mạnh nhất với mức độ béo phì ($r_{\text{Weight}} = 0,913$). Đây là kết quả hoàn toàn phù hợp với thực tế lâm sàng, bởi cân nặng là thành phần trực tiếp cấu thành nên chỉ số khối cơ thể (BMI) – cơ sở để phân loại mức độ béo phì. Ăn vặt giữa các bữa đứng thứ hai với hệ số tương quan thuận đạt ($r_{\text{CAEC}} = 0,329$). Điều này nhấn mạnh rằng hành vi ăn vặt, nạp năng lượng liên tục ngoài các bữa chính là tác nhân hàng đầu dẫn đến việc tích tụ mỡ thừa.

Nhóm các nhân tố bảo vệ (tương quan nghịch): Tiêu thụ rượu bia ($r_{\text{CALC}} = -0,152$) và tần suất hoạt động thể chất ($r_{\text{FAF}} = -0,2$) là hai biến có tương quan nghịch lớn nhất với mức độ béo phì. Việc hoạt động thể chất tích cực giúp đốt cháy năng lượng dư thừa, đóng vai trò như một cơ chế bảo vệ cơ thể khỏi nguy cơ tăng cân ngoài kiểm soát.


Qua các số liệu và tính toán chỉ số thống kê nhiều chiều, cuối cùng, khi xem xét tính đầy đủ của mô hình, ta nhận thấy ma trận hiệp phương sai mẫu là công cụ mô tả đầy đủ thông tin khi dữ liệu tuân theo phân phối chuẩn đa biến và các mối quan hệ là tuyến tính. Tuy nhiên, đối với bộ dữ liệu béo phì này, ma trận hiệp phương sai là chưa đủ để mô tả trọn vẹn dữ liệu. Nguyên nhân là do dữ liệu chứa đựng sự hỗn hợp giữa các biến định tính và định lượng, sự nhạy cảm của hiệp phương sai đối với các điểm ngoại lệ từ biến cân nặng, và đặc biệt là sự tồn tại của các cấu trúc phụ thuộc phi tuyến phức tạp. Do đó, để tối ưu hóa việc phân tích, cần thực hiện các kỹ thuật giảm chiều dữ liệu như Phân tích thành phần chính (PCA).

2.1.3 Bộ dữ liệu MNIST

Bộ dữ liệu MNIST (Modified National Institute of Standards and Technology) [?] là một trong những bộ dữ liệu chuẩn lâu đời và phổ biến nhất trong lĩnh vực thị giác máy tính và học máy. Được giới thiệu lần đầu bởi Yann LeCun và cộng sự vào năm 1998, MNIST đóng vai trò như một "bộ kiểm tra tiêu chuẩn" (benchmark) cho các bài toán phân loại ảnh cơ bản, đặc biệt là nhận dạng chữ số viết tay.

Bộ dữ liệu này bao gồm tổng cộng 70.000 ảnh xám, mỗi ảnh có kích thước 28×28 pixel. Các ảnh được phân chia thành hai tập con riêng biệt: tập huấn luyện gồm 60.000 ảnh và tập kiểm tra gồm 10.000 ảnh. Mỗi ảnh là một hình chữ số viết tay từ 0 đến 9, do đó bộ dữ liệu có 10 lớp cần phân biệt.

Một đặc điểm quan trọng của MNIST là tính đơn giản và độ sạch của dữ liệu. Các



Hình 2.3: Ví dụ về ảnh MNIST


ảnh đã được tiền xử lý để chuẩn hóa kích thước và căn chỉnh trung tâm, giúp giảm thiểu độ phức tạp không cần thiết. Nhờ vậy, các mô hình học máy cơ bản như k-láng giềng gần nhất (k-NN), máy véc-tơ hỗ trợ (SVM) hay các mạng nơ-ron đơn giản đều có thể đạt được độ chính xác rất cao, thường trên 98%. Các mô hình học sâu hiện đại thậm chí có thể vượt qua ngưỡng 99,7% trên tập kiểm tra.

Do tính chất "dễ" này, MNIST ngày nay thường không được sử dụng để đánh giá sức mạnh của các kiến trúc học sâu tiên tiến. Tuy nhiên, nó vẫn giữ vai trò quan trọng như một bộ dữ liệu khởi đầu (toy dataset) lý tưởng cho việc làm quen với thư viện học sâu, kiểm tra lỗi mã nguồn, hoặc minh họa các nguyên lý cơ bản của mạng nơ-ron tích chập (CNN).

2.1.4 Bộ dữ liệu CIFAR-10

Khác với MNIST, bộ dữ liệu CIFAR-10 (Canadian Institute for Advanced Research) [?] là một bài toán thử thách hơn đáng kể, phản ánh gần hơn với sự phức tạp của thế giới thực. Được xây dựng bởi Alex Krizhevsky, Vinod Nair và Geoffrey Hinton, CIFAR-10 bao gồm 60.000 ảnh màu RGB, mỗi ảnh có kích thước 32×32 pixel. Tập dữ liệu được chia thành 50.000 ảnh cho huấn luyện và 10.000 ảnh cho kiểm tra.

Điểm khác biệt then chốt của CIFAR-10 nằm ở nội dung ngữ nghĩa phong phú. Các ảnh được gán nhãn thuộc về một trong mười lớp đối tượng rời rạc: máy bay, ô tô, chim, mèo, hươu, chó, ếch, ngựa, tàu thủy và xe tải. Không giống như MNIST với các chữ số



Hình 2.4: Ví dụ về ảnh CIFAR-10

đơn giản trên nền đồng nhất, CIFAR-10 chứa các đối tượng ở nhiều tư thế, màu sắc, kích thước và nền cảnh phức tạp.

Sự khác biệt này tạo ra một bước nhảy vọt về độ khó. Trong khi MNIST có thể được giải quyết hiệu quả bằng các mô hình tuyến tính hoặc mạng nơ-ron nông, CIFAR-10 đòi hỏi các kiến trúc sâu hơn và các kỹ thuật tinh vi hơn như: sử dụng nhiều lớp tích chập, kỹ thuật tăng cường dữ liệu (data augmentation), chuẩn hóa batch (batch normalization), và các cơ chế chính quy hóa. Độ chính xác tốt nhất hiện tại trên CIFAR-10 vẫn là một bài toán mở, với các mô hình tiên tiến đạt khoảng 98-99%, nhưng cần sự đầu tư lớn về tính toán và kiến trúc.

Do độ phức tạp hợp lý, vừa đủ thách thức nhưng không quá lớn để trở nên bất khả thi, CIFAR-10 được sử dụng rộng rãi trong nghiên cứu học sâu như một tiêu chuẩn đánh giá cho các kiến trúc CNN mới, các phương pháp tối ưu hóa, và các kỹ thuật tổng quát hóa.

Chương 3

Phản biện giả thiết và phân tích hình học dữ liệu

3.1 Giả thiết dữ liệu có thể được xấp xỉ bởi phân phối chuẩn nhiều chiều

Trong phân tích đa biến, giả thiết phân phối chuẩn nhiều chiều nghĩa là vector dữ liệu:

$$X = (X_1, X_2, \dots, X_p)^T$$

được giả định tuân theo:

$$X \sim N_p(\mu, \Sigma)$$

trong đó:

- μ là vector trung bình,
- Σ là ma trận hiệp phương sai.

Đối với bộ dữ liệu béo phì, một số dấu hiệu có thể ủng hộ giả thiết này. Trước hết, các biến định lượng như **Age**, **Height**, **Weight** có xu hướng liên tục và có histogram dạng gần đối xứng, không quá lệch trái hoặc lệch phải, thì có thể xem chúng gần với phân phối chuẩn một chiều. Ngoài ra, nếu biểu đồ Q-Q của từng biến gần với đường thẳng, điều đó cho thấy phân phối biên của biến đó gần chuẩn. Bên cạnh đó, nếu khoảng cách Mahalanobis bình phương có phân phối gần với phân phối χ_p^2 , đây cũng là một dấu hiệu ủng hộ giả thiết chuẩn nhiều chiều.

Tuy nhiên, bộ dữ liệu cũng chứa nhiều dấu hiệu bác bỏ giả thiết này. Nhiều biến trong dữ liệu là biến phân loại hoặc biến nhị phân như **Gender**, **FAVC**, **SMOKE**, **SCC** và **family_history_with_overweight**. Các biến này không tuân theo phân phối chuẩn liên tục. Ngoài ra, biến mục tiêu **NObeyesdad** là biến phân loại mức độ béo phì nên không thể xem như biến chuẩn liên tục. Dữ liệu cũng có khả năng bao gồm nhiều nhóm đối tượng khác nhau như nhóm cân nặng bình thường, thừa cân và béo phì, dẫn đến phân phối tổng thể có thể là phân phối hỗn hợp thay vì một phân phối chuẩn duy nhất.

Nếu sử dụng các lập luận Gaussian trong khi giả thiết chuẩn nhiều chiều không đúng, kết quả phân tích có thể bị sai lệch. Chẳng hạn, việc phát hiện điểm ngoại lệ bằng khoảng cách Mahalanobis có thể không chính xác vì ngưỡng dựa trên phân phối χ_p^2 không còn phù hợp. Các kiểm định thống kê như Hotelling's ($\mathbf{T}^2$) hoặc các miền tin cậy hình ellipse cũng có thể cho kết luận không đáng tin cậy. Ngoài ra, việc xử lý các biến phân loại như biến liên tục chuẩn có thể làm mất ý nghĩa diễn giải thống kê.

3.2 Khoảng cách Euclidean và khoảng cách Mahalanobis

Khoảng cách Euclidean là khoảng cách hình học thông thường trong không gian nhiều chiều và được xác định bởi:

$$d_E(x) = \sqrt{(x - \mu)^T(x - \mu)}$$

Trong khi đó, khoảng cách Mahalanobis được định nghĩa như sau:

$$d_M(x) = \sqrt{(x - \mu)^T \Sigma^{-1}(x - \mu)}$$

Trong đó, Σ^{-1} là ma trận nghịch đảo của ma trận hiệp phương sai.

Hai khoảng cách này có thể cho thứ hạng khác nhau khi đánh giá mức độ bất thường của các quan sát. Khoảng cách Euclidean giả định rằng tất cả các biến có cùng thang đo và độc lập với nhau. Vì vậy, các biến có phương sai lớn, chẳng hạn như **Weight**, sẽ chi phối mạnh kết quả khoảng cách. Ngược lại, khoảng cách Mahalanobis có tính đến cả phương sai và tương quan giữa các biến thông qua ma trận Σ^{-1} .

Vai trò của ma trận Σ^{-1} là chuẩn hóa khoảng cách theo cấu trúc dữ liệu. Những biến có phương sai lớn sẽ bị giảm trọng số, trong khi những biến có phương sai nhỏ

sẽ có ảnh hưởng lớn hơn. Đồng thời, nếu hai biến có tương quan cao, khoảng cách Mahalanobis sẽ xem sự thay đổi đồng thời của chúng là bình thường hơn so với khoảng cách Euclidean.

Trong bộ dữ liệu béo phì, các biến như **Height** và **Weight** có tương quan đáng kể. Nếu sử dụng khoảng cách Euclidean, những cá nhân có cân nặng cao sẽ dễ bị xem là ngoại lệ mặc dù cân nặng đó có thể phù hợp với chiều cao tương ứng. Ngược lại, khoảng cách Mahalanobis sẽ đánh giá các quan sát dựa trên cấu trúc tổng thể của dữ liệu, do đó phù hợp hơn trong phát hiện điểm ngoại lệ đa biến.

3.3 Kiểm tra một số giả thiết sai

Một giả thiết sai thường gặp trong thống kê là: “Hai biến không tương quan thì có thể coi là độc lập.”

Giả thiết này không đúng trong trường hợp tổng quát. Hệ số tương quan bằng 0 chỉ cho biết không tồn tại mối quan hệ tuyến tính giữa hai biến, nhưng không loại trừ khả năng tồn tại quan hệ phi tuyến.

Trong bộ dữ liệu béo phì, một số biến như **Gender**, **FCVC** và **SMOKE** có hệ số tương quan rất nhỏ với biến mục tiêu **NObyesdad**. Tuy nhiên, điều đó không đồng nghĩa với việc chúng hoàn toàn độc lập với mức độ béo phì. Các biến này có thể ảnh hưởng gián tiếp thông qua tương tác với các yếu tố khác như chế độ ăn uống, hoạt động thể chất hoặc thói quen sinh hoạt.

Ví dụ, mặc dù biến **SMOKE** có hệ số tương quan gần bằng 0 với mức độ béo phì, hành vi hút thuốc vẫn có thể liên quan đến lối sống hoặc hoạt động thể chất của đối tượng nghiên cứu. Điều này cho thấy không thể kết luận độc lập chỉ dựa trên hệ số tương quan tuyến tính.

Một giả thiết sai khác là: “Chuẩn hóa không làm thay đổi bản chất phân tích.”

Trong thực tế, chuẩn hóa có ảnh hưởng rất lớn đối với các phương pháp phân tích đa biến như PCA. Trong dữ liệu béo phì, biến **Weight** có phương sai lớn hơn nhiều so với **Height**. Nếu không chuẩn hóa, PCA sẽ chủ yếu bị chi phối bởi biến **Weight**, khiến các thành phần chính không phản ánh đúng cấu trúc tổng thể của dữ liệu. Sau khi chuẩn hóa, mỗi biến đóng góp công bằng hơn vào quá trình phân tích. Vì vậy, chuẩn hóa có thể thay đổi đáng kể kết quả phân tích và không thể xem là một bước không ảnh hưởng đến bản chất dữ liệu.

Tóm lại, trong bộ dữ liệu béo phì, việc áp dụng các giả thiết thống kê cần được kiểm tra cẩn thận thay vì chấp nhận một cách mặc định. Những giả thiết như chuẩn nhiều chiều, không tương quan tương đương độc lập hay chuẩn hóa không ảnh hưởng đến phân tích đều có thể dẫn đến kết luận sai nếu không được đánh giá bằng dữ liệu thực tế.


Chương 4

Pipeline xử lý dữ liệu

Pipeline xử lý dữ liệu là một phương pháp tự động hóa các bước biến đổi dữ liệu thô thành dữ liệu đã được làm sạch và chuẩn hóa, sẵn sàng cho các thuật toán học máy. Giống như một dây chuyền sản xuất trong nhà máy, pipeline nhận đầu vào là dữ liệu thô, thực hiện tuần tự các công đoạn xử lý, và xuất ra sản phẩm là dữ liệu chất lượng cao. Trong bối cảnh của bài toán Phân tích thành phần chính (Principal Component Analysis - PCA), pipeline đóng vai trò then chốt trong việc chuẩn bị dữ liệu trước khi giảm chiều. Điều này đặc biệt quan trọng vì PCA là một thuật toán nhạy cảm với tỷ lệ của các biến số và dễ bị ảnh hưởng bởi các điểm ngoại lai.

Trước khi dữ liệu được đưa vào mô hình PCA, nó thường trải qua các bước xử lý tiền đề. Các bước này bao gồm các phép biến đổi dữ liệu như lọc, mã hóa và chuẩn hóa, nhằm đảm bảo tích hợp và xử lý dữ liệu phù hợp. Một pipeline điển hình cho bài toán PCA bao gồm năm bước chính: xử lý dữ liệu thiếu (điền giá trị trung vị cho biến số và mode cho biến phân loại), mã hóa biến phân loại (chuyển đổi dạng văn bản thành số, với biến nhị phân ánh xạ thành 0/1 và biến nhiều giá trị mã hóa one-hot), loại bỏ biến có phương sai thấp (xóa các biến ít thông tin), chuẩn hóa dữ liệu (chỉ áp dụng cho biến liên tục để đưa về cùng tỷ lệ với $\text{mean}=0$ và $\text{std}=1$), và cuối cùng là phát hiện và loại bỏ ngoại lai sử dụng khoảng cách Mahalanobis kết hợp với ngưỡng phân vị của phân phối chi-bình phương.

Một nguyên tắc vô cùng quan trọng khi xây dựng pipeline là đảm bảo tính nhất quán giữa tập huấn luyện (train) và tập kiểm tra (test). Cụ thể, tất cả các tham số như giá trị trung bình, độ lệch chuẩn, ngưỡng phương sai và ma trận hiệp phương sai đều phải được tính toán và lưu lại từ tập huấn luyện, sau đó được sử dụng để biến



Hình 4.1: Pipeline xử lý dữ liệu

đổi tập kiểm tra. Đặc biệt, việc phát hiện và loại bỏ ngoại lai chỉ được thực hiện trên tập huấn luyện, không áp dụng cho tập kiểm tra. Điều này đảm bảo không có sự rò rỉ thông tin từ tập kiểm tra sang quá trình huấn luyện, giúp đánh giá mô hình một cách khách quan và chính xác. Nhờ có pipeline xử lý dữ liệu, các công đoạn xử lý dữ liệu có thể được quy trình hóa và tập trung vào việc xây dựng và tối ưu hóa mô hình PCA thay vì mất thời gian vào các công đoạn tiền xử lý thủ công, đồng thời vẫn đảm bảo được chất lượng và tính nhất quán của dữ liệu đầu vào.

4.1 Các thành phần chính của Pipeline

Như tên gọi của nó, pipeline xử lý dữ liệu đóng vai trò như "đường ống" dẫn dữ liệu cho các dự án khoa học dữ liệu. Dữ liệu có thể được lấy từ nhiều nguồn khác nhau—APIs, cơ sở dữ liệu SQL và NoSQL, file, v.v.—nhưng không may là dữ liệu thô thường chưa sẵn sàng để sử dụng ngay. Dưới đây là pipeline xử lý dữ liệu được thiết kế riêng cho bài toán PCA. Sơ đồ tổng quan của Pipeline được cho bởi Hình. 4.1.

4.1.1 Tách tập huấn luyện và tập kiểm tra (Train-Test Split)

Bước đầu tiên và cũng là một trong những bước quan trọng nhất trong pipeline xử lý dữ liệu là tách tập dữ liệu ban đầu thành hai phần riêng biệt: tập huấn luyện (training set) và tập kiểm tra (test set). Việc tách dữ liệu phải được thực hiện ngay từ đầu, trước khi tiến hành bất kỳ bước xử lý hay biến đổi nào khác. Nguyên tắc cốt lõi ở bước này là tuyệt đối không để bất kỳ thông tin nào từ tập kiểm tra làm ảnh hưởng

đến quá trình huấn luyện mô hình. Điều này đảm bảo rằng khi đánh giá mô hình sau này, chúng ta đang đánh giá trên dữ liệu mà mô hình chưa từng được nhìn thấy, phản ánh đúng hiệu năng thực tế khi triển khai.

Thông thường, dữ liệu được chia theo tỷ lệ 80% cho tập huấn luyện và 20% cho tập kiểm tra, mặc dù tỷ lệ này có thể điều chỉnh tùy thuộc vào kích thước của bộ dữ liệu. Đối với các bộ dữ liệu nhỏ, tỷ lệ có thể là 70/30 hoặc thậm chí 60/40; đối với bộ dữ liệu rất lớn, tỷ lệ 90/10 hoặc 95/5 có thể được sử dụng. Trong pipeline được triển khai, tham số `test_size` được sử dụng để xác định tỷ lệ này và `random_state` được thiết lập để đảm bảo tính tái lập (reproducibility) của kết quả.

Một kỹ thuật quan trọng được sử dụng trong bước tách dữ liệu là *stratified sampling* (lấy mẫu phân tầng). Kỹ thuật này đảm bảo rằng tỷ lệ phân bố của các lớp trong biến mục tiêu được bảo toàn giữa tập huấn luyện và tập kiểm tra. Điều này đặc biệt quan trọng đối với các bài toán phân loại có sự mất cân bằng giữa các lớp (class imbalance). Ví dụ, trong bộ dữ liệu về béo phì, nếu có 70% mẫu thuộc lớp "Normal Weight" và chỉ 5% mẫu thuộc lớp "Insufficient Weight", việc sử dụng stratified sampling đảm bảo rằng cả hai tập huấn luyện và kiểm tra đều giữ được tỷ lệ này, tránh trường hợp tập kiểm tra không có đại diện của một lớp nào đó.

Trong code pipeline, việc tách dữ liệu được thực hiện như sau:

```
from sklearn.model_selection import train_test_split

data_train, data_test = train_test_split(
    data,
    test_size=0.2,
    random_state=42,
    stratify=data['NObeyesdad']
)
```

Tham số `stratify=data['NObeyesdad']` chỉ ra rằng việc tách dữ liệu sẽ dựa trên phân phối của biến mục tiêu `NObeyesdad`. Tham số `random_state=42` đảm bảo rằng mỗi lần chạy lại pipeline, kết quả tách dữ liệu là giống nhau, giúp cho việc tái tạo kết quả nghiên cứu trở nên khả thi.

Sau khi tách, chúng ta thu được hai đối tượng DataFrame riêng biệt: `data_train` và `data_test`. Cả hai đều chứa đầy đủ các cột đặc trưng (features) và cột mục tiêu

(target). Việc giữ nguyên cấu trúc này cho phép các bước xử lý tiếp theo trong pipeline có thể thao tác trên cả hai tập một cách nhất quán. Cần lưu ý rằng mọi tham số được tính toán từ bước xử lý sau này (như giá trị trung bình, độ lệch chuẩn, danh sách các cột cần giữ lại, ma trận hiệp phương sai) đều chỉ được ước lượng từ tập huấn luyện, sau đó áp dụng để biến đổi cả tập huấn luyện và tập kiểm tra.

Việc thực hiện tách dữ liệu ngay từ đầu mang lại nhiều lợi ích quan trọng. Thứ nhất, nó ngăn chặn hoàn toàn nguy cơ rò rỉ dữ liệu (data leakage) - một vấn đề phổ biến khi các bước tiền xử lý được thực hiện trước khi tách dữ liệu. Thứ hai, nó cho phép đánh giá mô hình một cách khách quan và đáng tin cậy. Thứ ba, nó tạo ra một quy trình có tính tái lập cao, giúp các nhà nghiên cứu khác có thể kiểm tra và xác nhận kết quả. Cuối cùng, việc tách dữ liệu sớm mô phỏng chính xác tình huống thực tế khi mô hình được triển khai: nó sẽ phải xử lý những dữ liệu mới, chưa từng được nhìn thấy trong quá trình huấn luyện.

Tóm lại, bước tách tập huấn luyện và tập kiểm tra không chỉ đơn thuần là một thao tác kỹ thuật, mà còn là nền tảng cho toàn bộ quy trình đánh giá mô hình một cách khoa học và khách quan. Việc thực hiện đúng bước này ngay từ đầu pipeline là tiền đề để xây dựng các mô hình học máy có khả năng tổng quát hóa tốt trên dữ liệu mới.

4.1.2 Xử lý nhãn (Labels Separation)

Sau khi đã hoàn thành bước tách tập huấn luyện và tập kiểm tra, bước tiếp theo trong pipeline là tách riêng biến mục tiêu (target variable) ra khỏi các biến đặc trưng (features). Biến mục tiêu là biến mà mô hình học máy cần dự đoán, ví dụ trong bài toán phân loại mức độ béo phì, biến mục tiêu là `NObeyesdad` với các giá trị từ 0 đến 6 tương ứng với bảy mức độ khác nhau. Biến mục tiêu có bản chất hoàn toàn khác với các biến đặc trưng, do đó nó sẽ không trải qua các bước xử lý như chuẩn hóa, mã hóa hay loại bỏ ngoại lai giống như các biến đặc trưng.

Việc tách nhãn sớm ngay sau khi chia tập dữ liệu mang lại nhiều lợi ích quan trọng. Thứ nhất, nó đảm bảo rằng tất cả các bước tiền xử lý tiếp theo (xử lý dữ liệu thiếu, mã hóa biến phân loại, chuẩn hóa, loại bỏ phương sai thấp, phát hiện ngoại lai) chỉ được áp dụng trên các biến đặc trưng, tránh làm sai lệch hoặc làm thay đổi giá trị của nhãn. Thứ hai, việc giữ nhãn riêng biệt giúp dễ dàng theo dõi và kiểm tra tính toàn vẹn của dữ liệu đầu ra. Thứ ba, khi huấn luyện mô hình, chúng ta cần có nhãn ở dạng

nguyên bản, không qua bất kỳ phép biến đổi nào.

Trong code pipeline, việc tách nhãn được thực hiện như sau:

```
# Split target
y = None
if self.target_col is not None:
    y = data[self.target_col]
    data = data.drop(columns=[self.target_col])
```

Đoạn code trên hoạt động với cơ chế sau: đầu tiên, biến `y` được khởi tạo với giá trị `None`. Sau đó, kiểm tra xem tham số `target_col` có được cung cấp hay không. Nếu có, cột tương ứng với tên của biến mục tiêu sẽ được trích xuất và lưu vào biến `y`, đồng thời cột này bị loại bỏ khỏi DataFrame `data` bằng phương thức `drop()`. Kết quả là `data` lúc này chỉ chứa các biến đặc trưng, còn `y` chứa toàn bộ nhãn tương ứng.

Phương pháp thiết kế pipeline sử dụng tham số `target_col` ngay từ khi khởi tạo cho phép pipeline linh hoạt làm việc với nhiều bộ dữ liệu khác nhau, mỗi bộ có thể có tên cột mục tiêu khác nhau. Ví dụ:

```
# Khởi tạo pipeline cho bài toán béo phì
pipeline = DataPipeline(target_col="NObeyesdad")

# Hoặc cho bài toán MNIST
pipeline = DataPipeline(target_col="target")
```

Sau bước tách nhãn, pipeline sẽ xử lý riêng biệt hai luồng dữ liệu: luồng đặc trưng sẽ đi qua các bước tiền xử lý phức tạp (làm sạch, mã hóa, chuẩn hóa, loại bỏ ngoại lai), trong khi luồng nhãn được giữ nguyên và chỉ được truyền thẳng đến đầu ra. Cuối cùng, pipeline trả về hai giá trị: `data` đã qua xử lý và `y` được giữ nguyên, sẵn sàng cho việc huấn luyện mô hình.

```
return data, y
```

Cần lưu ý rằng việc tách nhãn được thực hiện riêng biệt trên cả tập huấn luyện và tập kiểm tra, nhưng theo cùng một cơ chế. Đối với tập kiểm tra, biến mục tiêu (nếu có)

cũng được tách ra để sau này sử dụng cho việc đánh giá mô hình, nhưng không bao giờ được sử dụng trong quá trình huấn luyện.

Tóm lại, bước xử lý nhãn tuy đơn giản nhưng đóng vai trò then chốt trong việc tổ chức luồng dữ liệu xuyên suốt pipeline. Việc tách biệt rõ ràng giữa đặc trưng và nhãn giúp pipeline hoạt động một cách có cấu trúc, dễ hiểu và dễ bảo trì, đồng thời đảm bảo rằng các bước tiền xử lý chỉ tác động lên đúng các thành phần cần thiết.

4.1.3 Xử lý dữ liệu thiếu (Handle Missing Values)

Dữ liệu trong thực tế thường có các giá trị bị thiếu do nhiều nguyên nhân khác nhau như lỗi trong quá trình thu thập dữ liệu, nhập liệu không đầy đủ, sự cố hệ thống hoặc do người dùng từ chối cung cấp thông tin. Việc xử lý các giá trị thiếu là một bước bắt buộc và không thể bỏ qua trước khi đưa dữ liệu vào bất kỳ mô hình học máy nào, bởi vì hầu hết các thuật toán đều yêu cầu dữ liệu đầu vào phải đầy đủ và không có giá trị null.

Trong pipeline được xây dựng, phương pháp `handle_missing` đảm nhận nhiệm vụ xử lý dữ liệu thiếu. Phương thức này hoạt động dựa trên nguyên tắc phân loại kiểu dữ liệu: các cột số (numerical) và các cột phân loại (categorical) được xử lý bằng các phương pháp khác nhau.

```
def handle_missing(self, df):
    data = df.copy()
    self.numeric_cols = data.select_dtypes(
        include=["int64", "float64"]
    ).columns.tolist()
    self.categorical_cols = data.select_dtypes(
        include=["object"]
    ).columns.tolist()

    # Numeric -> median
    for col in self.numeric_cols:
        median_value = data[col].median()
        data[col] = data[col].fillna(median_value)
```

```
# Categorical -> mode
for col in self.categorical_cols:
    mode_value = data[col].mode()[0]
    data[col] = data[col].fillna(mode_value)

return data
```

Đối với các biến số (numerical), giá trị trung vị (median) được sử dụng để thay thế các giá trị thiếu. Việc lựa chọn median thay vì mean (giá trị trung bình) là có cơ sở thống kê vững chắc: median là thước đo xu hướng trung tâm ít bị ảnh hưởng bởi các điểm ngoại lai (outliers) so với mean. Trong các bộ dữ liệu thực tế thường có sự hiện diện của các giá trị bất thường, việc sử dụng median giúp tránh làm lệch phân phối của dữ liệu sau khi điền. Ví dụ, nếu một biến như thu nhập có một vài giá trị rất cao (cá biệt), giá trị trung bình sẽ bị kéo lên cao trong khi median vẫn đại diện tốt cho xu hướng trung tâm của phần lớn dữ liệu.

Đối với các biến phân loại (categorical), giá trị xuất hiện nhiều nhất (mode) được sử dụng để thay thế. Mode là lựa chọn hợp lý vì nó đại diện cho danh mục phổ biến nhất trong dữ liệu, phản ánh xu hướng chiếm ưu thế của một giá trị nào đó. Ví dụ, trong biến CAEC (thói quen ăn giữa các bữa chính), nếu giá trị 'Sometimes' xuất hiện nhiều nhất, việc điền các giá trị thiếu bằng 'Sometimes' là một giả định hợp lý.

Một nguyên tắc cực kỳ quan trọng trong bước xử lý dữ liệu thiếu là các tham số (median và mode) chỉ được tính toán trên tập huấn luyện (training set), sau đó được lưu lại và sử dụng để điền vào cả tập huấn luyện và tập kiểm tra (test set). Điều này đảm bảo không có sự rò rỉ thông tin từ tập kiểm tra sang quá trình huấn luyện. Trong code, các giá trị median được tính trực tiếp từ tập dữ liệu đầu vào (là tập huấn luyện) và được áp dụng ngay lập tức. Khi xử lý tập kiểm tra, pipeline sẽ sử dụng các median đã được lưu trữ để điền giá trị thiếu.

Việc xác định các cột số và cột phân loại được thực hiện tự động thông qua phương thức `select_dtypes`. Điều này giúp pipeline có thể làm việc với bất kỳ bộ dữ liệu nào mà không cần cấu hình thủ công. Các cột có kiểu dữ liệu `int64` hoặc `float64` được coi là biến số, các cột có kiểu `object` được coi là biến phân loại. Cách tiếp cận này vừa linh hoạt vừa chính xác cho hầu hết các bộ dữ liệu thực tế.

Sau khi hoàn thành bước xử lý dữ liệu thiếu, toàn bộ các giá trị NaN hoặc null đã

được thay thế bằng các giá trị phù hợp. Dữ liệu lúc này đã sẵn sàng để chuyển sang bước tiếp theo: mã hóa các biến phân loại. Cần lưu ý rằng việc xử lý dữ liệu thiếu cần được thực hiện trước khi mã hóa, bởi vì các thuật toán mã hóa như `LabelEncoder` không thể hoạt động trên các giá trị null.

Tóm lại, bước xử lý dữ liệu thiếu là một bước không thể thiếu trong pipeline, giúp đảm bảo tính toàn vẹn và chất lượng của dữ liệu đầu vào cho các bước xử lý tiếp theo cũng như cho mô hình học máy.

4.1.4 Mã hóa dữ liệu (Data Encoding)

Các thuật toán học máy chỉ có thể làm việc với dữ liệu dạng số. Do đó, các biến phân loại cần được chuyển đổi sang dạng số. Trong pipeline được xây dựng, phương thức `encode_categorical` xử lý các biến phân loại theo từng trường hợp cụ thể.

Đối với các biến nhị phân như `Gender`, `SMOKE`, `SCC`, `family_history_with_overweight`, việc ánh xạ trực tiếp thành 0 và 1 được thực hiện thông qua từ điển mapping. Cách tiếp cận này giữ nguyên bản chất nhị phân của biến.

Đối với biến mục tiêu `NObedesdad`, một mapping riêng được sử dụng để chuyển đổi bảy mức độ béo phì thành giá trị số từ 0 đến 6.

Đối với các biến phân loại còn lại như `CAEC`, `CALC`, `MTRANS`, pipeline sử dụng `LabelEncoder` từ thư viện `scikit-learn` để chuyển đổi thành các giá trị số nguyên (0, 1, 2, ...). Phương pháp này được gọi là label encoding.

`else:`

```
data[col] = le.fit_transform(data[col])
self.label_maps[col] = dict(zip(le.classes_, le.transform(le.classes_)))
```

Các bộ mã hóa chỉ được huấn luyện trên tập huấn luyện và sau đó áp dụng cho tập kiểm tra, đảm bảo tính nhất quán và tránh rò rỉ thông tin. Đối với `LabelEncoder`, các ánh xạ giữa nhãn gốc và giá trị số được lưu trong `label_maps` để sử dụng khi transform dữ liệu kiểm tra.

Cần lưu ý rằng phương pháp label encoding có thể tạo ra mối quan hệ thứ tự giả tạo giữa các danh mục (ví dụ: nếu gán xe máy = 1, ô tô = 2, xe buýt = 3 thì thuật toán có thể hiểu nhầm rằng xe buýt lớn hơn xe máy). Tuy nhiên, đối với các thuật toán

dạng cây như Random Forest, vấn đề này ít ảnh hưởng hơn so với các thuật toán dạng hồi quy tuyến tính.

4.1.5 Chuẩn hóa đặc trưng (Standardize Feature)

Đối với các biến liên tục, bước chuẩn hóa (standardization) được thực hiện nhằm đưa tất cả các biến về cùng một tỷ lệ, loại bỏ sự khác biệt về đơn vị đo lường. Công thức chuẩn hóa được sử dụng trong pipeline là:

$$X_{standardized} = \frac{X - \mu}{\sigma}$$

Trong đó μ là giá trị trung bình (mean) và σ là độ lệch chuẩn (standard deviation) của biến đó được tính toán trên tập huấn luyện. Sau khi chuẩn hóa, các biến sẽ có giá trị trung bình bằng 0 và độ lệch chuẩn bằng 1, hay nói cách khác, chúng được chuyển về phân phối chuẩn tắc (standard normal distribution).

Bước chuẩn hóa này đặc biệt quan trọng đối với thuật toán PCA vì những lý do sau đây. Thứ nhất, PCA hoạt động dựa trên việc tìm kiếm các hướng có phương sai lớn nhất trong không gian dữ liệu. Nếu không chuẩn hóa, các biến có đơn vị đo lớn hơn sẽ có phương sai lớn hơn một cách tự nhiên và do đó sẽ chi phối các thành phần chính một cách không mong muốn. Ví dụ, cân nặng tính bằng kilogram (khoảng 50-100) có phương sai lớn hơn nhiều so với chiều cao tính bằng mét (khoảng 1.5-1.8), mặc dù cả hai đều là những đặc trưng quan trọng. Nếu không chuẩn hóa, thành phần chính đầu tiên gần như sẽ chỉ phản ánh sự biến thiên của cân nặng mà bỏ qua chiều cao. Thứ hai, các biến có đơn vị đo khác nhau (tuổi tính bằng năm, chiều cao tính bằng cm, cân nặng tính bằng kg, số bữa ăn tính bằng lần/ngày) là không thể so sánh trực tiếp với nhau. Chuẩn hóa giúp đưa chúng về cùng một thang đo, cho phép so sánh ý nghĩa thống kê giữa các hệ số.

Trong pipeline được triển khai, các biến liên tục được xác định trước bao gồm: **Age** (tuổi), **Height** (chiều cao), **Weight** (cân nặng), **FCVC** (tần suất ăn rau), **NCP** (số bữa ăn chính), **CH20** (lượng nước uống hàng ngày), **FAF** (tần suất hoạt động thể chất), **TUE** (thời gian sử dụng thiết bị điện tử). Tám biến này có bản chất là số đo liên tục và có đơn vị khác nhau, do đó cần được chuẩn hóa.

Quy trình chuẩn hóa trong pipeline được thực hiện như sau. Đầu tiên, trên tập huấn luyện, giá trị trung bình μ và độ lệch chuẩn σ của mỗi biến liên tục được tính

toán và lưu lại. Sau đó, các giá trị này được sử dụng để chuẩn hóa cả tập huấn luyện và tập kiểm tra theo cùng một công thức. Việc lưu lại các tham số μ và σ là rất quan trọng vì khi áp dụng pipeline cho dữ liệu mới (tập kiểm tra hoặc dữ liệu trong tương lai), chúng ta phải sử dụng chính các tham số đã học từ tập huấn luyện để đảm bảo tính nhất quán. Không được tính toán lại μ và σ trên tập kiểm tra vì điều đó sẽ làm rò rỉ thông tin và đánh giá mô hình không còn khách quan.

Điều quan trọng cần lưu ý là các biến nhị phân và các biến đã được mã hóa one-hot sẽ không trải qua bước chuẩn hóa này. Lý do là các biến này đã ở dạng 0/1, và việc chuẩn hóa chúng sẽ làm mất đi ý nghĩa nhị phân vốn có. Một biến nhị phân sau khi chuẩn hóa sẽ có các giá trị không còn là 0 và 1 nữa (ví dụ -0.3 và 0.7), khiến cho việc giải thích trở nên khó khăn và không còn ý nghĩa thực tế. Hơn nữa, các biến nhị phân đã có sẵn thang đo chung (0 và 1) nên không cần thiết phải chuẩn hóa.

Tóm lại, bước chuẩn hóa là một bước không thể thiếu trong pipeline, đặc biệt khi sử dụng PCA. Nó đảm bảo rằng mỗi biến đều có cơ hội đóng góp công bằng vào việc xác định các thành phần chính, đồng thời giúp cải thiện tính ổn định và hội tụ của các thuật toán học máy. Việc chỉ chuẩn hóa các biến liên tục và giữ nguyên các biến nhị phân phản ánh sự hiểu biết sâu sắc về bản chất của từng loại dữ liệu.

4.1.6 Loại bỏ biến có phương sai thấp (Remove Low Variance)

Các biến có phương sai thấp (low variance features) là những biến có giá trị gần như không thay đổi giữa các mẫu dữ liệu. Những biến này chứa rất ít thông tin và hầu như không đóng góp gì vào quá trình phân tích cũng như huấn luyện mô hình. Việc loại bỏ chúng giúp giảm số chiều của dữ liệu ngay từ đầu, đồng thời giảm thiểu nhiễu và cải thiện hiệu suất tính toán.

Trong pipeline được xây dựng, phương thức `remove_low_variance` đảm nhận nhiệm vụ này. Đầu tiên, phương thức tính phương sai của từng cột trong tập huấn luyện bằng hàm `var()` của pandas. Sau đó, các cột có phương sai nhỏ hơn ngưỡng `low_variance_threshold` (thường được đặt là 0.01) sẽ bị loại bỏ. Danh sách các cột được giữ lại được lưu trong biến `self.selected_columns` để sử dụng cho việc transform dữ liệu kiểm tra sau này.

```
def remove_low_variance(self, df):
    data = df.copy()
```

```

variances = data.var()
keep_cols = variances[
    variances >= self.low_variance_threshold
].index.tolist()
self.selected_columns = keep_cols
return data[keep_cols]

```

Việc lựa chọn ngưỡng phương sai là một quyết định quan trọng. Nếu ngưỡng quá cao, có thể loại bỏ những biến có giá trị thông tin; nếu ngưỡng quá thấp, vẫn giữ lại nhiều biến có ít thông tin. Trong thực tế, ngưỡng 0.01 thường được sử dụng làm giá trị mặc định. Đối với các bộ dữ liệu đã được chuẩn hóa (các biến có cùng thang đo), một biến có phương sai nhỏ hơn 0.01 có nghĩa là hầu hết các giá trị của nó đều rất gần với giá trị trung bình, tức là biến đó hầu như không thay đổi.

Một điểm quan trọng cần lưu ý là việc loại bỏ biến có phương sai thấp chỉ được thực hiện dựa trên tập huấn luyện. Danh sách các cột được giữ lại (`self.selected_columns`) sau đó được áp dụng để lọc cả tập huấn luyện và tập kiểm tra, đảm bảo tính nhất quán về số lượng và tên cột giữa hai tập dữ liệu. Điều này đặc biệt quan trọng khi sử dụng các mô hình học máy yêu cầu dữ liệu đầu vào có cùng số chiều.

4.1.7 Phát hiện và loại bỏ ngoại lai (Outlier Detection)

Bước cuối cùng và cũng là một trong những bước quan trọng nhất trong pipeline xử lý dữ liệu là phát hiện và loại bỏ các điểm ngoại lai (outliers). Trong bối cảnh đa biến (nhiều biến số), một điểm có thể là ngoại lai không phải vì giá trị của một biến riêng lẻ quá lớn hay quá nhỏ, mà vì sự kết hợp bất thường giữa các biến. Ví dụ, một người có chiều cao bình thường nhưng cân nặng quá thấp so với chiều cao đó có thể được coi là ngoại lai trong không gian hai chiều (chiều cao, cân nặng), mặc dù cả hai giá trị riêng lẻ đều nằm trong khoảng bình thường.

Phương pháp được sử dụng trong pipeline là khoảng cách Mahalanobis (Mahalanobis distance), một kỹ thuật phát hiện ngoại lai đa biến có tính đến cấu trúc tương quan giữa các biến. Khoảng cách Mahalanobis có nhiều ưu điểm so với các phương pháp phát hiện ngoại lai đơn biến như Z-score. Thứ nhất, nó tự động chuẩn hóa các biến, loại bỏ ảnh hưởng của đơn vị đo. Thứ hai, nó tính đến mối tương quan giữa các biến, do đó có thể phát hiện các điểm ngoại lai trong không gian đa chiều mà các phương

pháp đơn biến không thể phát hiện. Thứ ba, dưới giả định rằng dữ liệu tuân theo phân phối chuẩn đa biến (multivariate normal distribution), bình phương khoảng cách Mahalanobis tuân theo phân phối chi-bình phương (chi-square distribution) với p bậc tự do, trong đó p là số lượng biến.

Trong pipeline, việc phát hiện ngoại lai được thực hiện như sau:

```
def detect_outliers(self, X):
    mean_vec = np.mean(X, axis=0)
    cov_matrix = np.cov(X, rowvar=False)
    inv_cov_matrix = np.linalg.pinv(cov_matrix)

    distances = []
    for row in X:
        d = mahalanobis(row, mean_vec, inv_cov_matrix)
        distances.append(d)

    mahal_sq = np.array(distances) ** 2
    p = X.shape[1]
    threshold = chi2.ppf(self.outlier_alpha, df=p)
    outlier_mask = mahal_sq > threshold
    return outlier_mask
```

Ngưỡng để xác định một điểm là ngoại lai được xác định dựa trên phân phối chi-bình phương. Tham số `outlier_alpha` (thường được đặt là 0.975) xác định phân vị của phân phối chi-bình phương được sử dụng làm ngưỡng. Cụ thể, với `outlier_alpha = 0.975`, một điểm được coi là ngoại lai nếu bình phương khoảng cách Mahalanobis của nó lớn hơn phân vị thứ 97.5% của phân phối chi-bình phương với p bậc tự do. Điều này có nghĩa là nếu dữ liệu thực sự tuân theo phân phối chuẩn đa biến, chỉ có khoảng 2.5% số điểm bị coi là ngoại lai một cách tự nhiên.

Một nguyên tắc cực kỳ quan trọng cần được nhấn mạnh là **việc phát hiện và loại bỏ ngoại lai chỉ được thực hiện trên tập huấn luyện**. Tập kiểm tra (test set) sẽ không trải qua bước này vì những lý do sau. Thứ nhất, trong thực tế khi triển khai mô hình vào sản xuất, chúng ta không thể biết trước một điểm dữ liệu mới có phải là ngoại lai

hay không, và cũng không thể loại bỏ nó khỏi dữ liệu cần dự đoán. Thứ hai, việc loại bỏ ngoại lai trên tập kiểm tra sẽ làm sai lệch đánh giá hiệu năng thực sự của mô hình, khiến cho kết quả đánh giá trở nên lạc quan một cách giả tạo. Thứ ba, các điểm ngoại lai trong tập kiểm tra vẫn cần được mô hình xử lý; việc loại bỏ chúng tương đương với việc thay đổi phân phối dữ liệu cần đánh giá.

Trong pipeline, đối với tập huấn luyện, phương thức `fit_transform` thực hiện phát hiện ngoại lai và loại bỏ chúng. Đối với tập kiểm tra, phương thức `fit_test_transform` được sử dụng để chỉ áp dụng các bước xử lý khác (xử lý thiếu, mã hóa, chuẩn hóa) mà không thực hiện phát hiện và loại bỏ ngoại lai.

```
X_continuous = data[continuous_cols].values
outlier_mask = self.detect_outliers(X_continuous)

if self.remove_outlier:
    data = data.loc[~outlier_mask]
    if y is not None:
        y = y.loc[~outlier_mask]
```

Cần lưu ý rằng việc phát hiện ngoại lai chỉ được áp dụng trên các biến liên tục (continuous variables) như `Age`, `Height`, `Weight`, `FCVC`, `NCP`, `CH2O`, `FAF`, `TUE`. Các biến nhị phân và biến phân loại không được đưa vào tính toán khoảng cách Mahalanobis vì chúng không có ý nghĩa trong không gian liên tục và sẽ làm sai lệch kết quả. Điều này được thể hiện qua dòng code `X_continuous = data[continuous_cols].values`.

Tóm lại, bước phát hiện và loại bỏ ngoại lai sử dụng khoảng cách Mahalanobis là một kỹ thuật mạnh mẽ để làm sạch dữ liệu huấn luyện, giúp mô hình học được cấu trúc tổng quát của dữ liệu mà không bị phân tâm bởi những điểm bất thường. Việc chỉ áp dụng bước này trên tập huấn luyện và không áp dụng trên tập kiểm tra đảm bảo đánh giá mô hình một cách khách quan và thực tế.

4.1.8 Kết quả đầu ra (Processed Train Set và Processed Test Set)

Sau khi hoàn thành tất cả các bước trên, pipeline xuất ra hai tập dữ liệu đã được xử lý: tập huấn luyện đã xử lý (Processed Train Set) và tập kiểm tra đã xử lý (Processed

Test Set). Cả hai tập dữ liệu này đều đã được làm sạch, mã hóa, chuẩn hóa (đối với biến liên tục), loại bỏ các biến có phương sai thấp, và tập huấn luyện đã được loại bỏ các điểm ngoại lai. Lúc này, dữ liệu đã sẵn sàng để đưa vào các mô hình học máy, bao gồm cả PCA để thực hiện giảm chiều. Việc có cả hai tập huấn luyện và kiểm tra riêng biệt đảm bảo rằng quá trình đánh giá mô hình được thực hiện một cách khách quan và đáng tin cậy.

4.1.9 Tổng kết pipeline

Tóm lại, pipeline xử lý dữ liệu là một quy trình tuần tự gồm nhiều bước được thiết kế để biến đổi dữ liệu thô thành dữ liệu sạch và chuẩn hóa. Mỗi bước trong pipeline đều tuân thủ nguyên tắc "fit trên train, transform trên test", đảm bảo không có sự rò rỉ thông tin từ tập kiểm tra. Pipeline không chỉ giúp tự động hóa các công đoạn xử lý dữ liệu mà còn đảm bảo tính nhất quán và khả năng tái tạo của toàn bộ quy trình phân tích. Đối với bài toán PCA, một pipeline được xây dựng tốt là yếu tố tiên quyết để đảm bảo các thành phần chính được trích xuất phản ánh đúng cấu trúc thực sự của dữ liệu.

Chương 5

Mô hình nâng cao đề xuất

5.1 Giới thiệu

Phương pháp phân tích thành phần chính (principal component analysis) nhằm giải thích cấu trúc phương sai–hiệp phương sai của một tập hợp các biến thông qua một vài tổ hợp tuyến tính của các biến này. Các mục tiêu tổng quát của nó là (1) giảm dữ liệu và (2) giải thích dữ liệu.

Mặc dù cần p thành phần để tái tạo toàn bộ sự biến thiên của hệ thống, thông thường phần lớn sự biến thiên này có thể được giải thích bởi một số lượng nhỏ k các thành phần chính. Nếu vậy, thông tin chứa trong k thành phần gần như tương đương với thông tin trong p biến ban đầu. Khi đó, k thành phần chính có thể thay thế cho p biến ban đầu, và tập dữ liệu gốc gồm n quan sát trên p biến được giảm thành tập dữ liệu gồm n quan sát trên k thành phần chính.

Một phân tích các thành phần chính thường tiết lộ các mối quan hệ mà trước đây chưa từng được nghi ngờ, qua đó cho phép đưa ra các giải thích mà thông thường không thể có được. Các phân tích thành phần chính thường là phương tiện để đạt được mục đích chứ không phải là mục đích tự thân, bởi vì chúng thường đóng vai trò là các bước trung gian trong các nghiên cứu lớn hơn nhiều. Ví dụ, các thành phần chính có thể là đầu vào cho hồi quy bội hoặc phân tích cụm. Hơn nữa, các thành phần chính (đã được tỷ lệ hóa) là một cách "phân tích nhân tử" của ma trận hiệp phương sai cho mô hình phân tích nhân tố.

5.2 Cơ sở toán học của PCA

Về mặt đại số, các thành phần chính là những tổ hợp tuyến tính đặc biệt của p biến ngẫu nhiên $X_1, X_2, \dots, X_p$. Về mặt hình học, những tổ hợp tuyến tính này biểu diễn sự lựa chọn của một hệ tọa độ mới thu được bằng cách xoay hệ tọa độ ban đầu, với $X_1, X_2, \dots, X_p$ là các trục tọa độ. Các trục mới đại diện cho các hướng có tính biến thiên tối đa và cung cấp một mô tả đơn giản hơn, tiết kiệm hơn về cấu trúc hiệp phương sai.

Như chúng ta sẽ thấy, các thành phần chính chỉ phụ thuộc vào ma trận hiệp phương sai Σ (hoặc ma trận tương quan P) của $X_1, X_2, \dots, X_p$. Việc phát triển chúng không yêu cầu giả định về phân phối chuẩn đa biến. Mặt khác, các thành phần chính được rút ra cho tổng thể có phân phối chuẩn đa biến mang những ý nghĩa hữu ích liên quan đến các ellipsoid mật độ hằng số. Hơn nữa, có thể đưa ra các suy luận từ các thành phần mẫu khi tổng thể có phân phối chuẩn đa biến [4].

Xét véc-tơ ngẫu nhiên $X' = [X_1, X_2, \dots, X_p]$ có ma trận hiệp phương sai Σ với các giá trị riêng $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$.

Xét các tổ hợp tuyến tính:

$$\begin{aligned} Y_1 &= a'_1 X = a_{11}X_1 + a_{12}X_2 + \dots + a_{1p}X_p \\ Y_2 &= a'_2 X = a_{21}X_1 + a_{22}X_2 + \dots + a_{2p}X_p \\ &\vdots \\ Y_p &= a'_p X = a_{p1}X_1 + a_{p2}X_2 + \dots + a_{pp}X_p \end{aligned}$$

Khi đó, dựa theo công thức tính toán phương sai, chúng ta thu được:

$$\text{Var}(Y_i) = a'_i \Sigma a_i \quad i = 1, 2, \dots, p \quad (5.1)$$

$$\text{Cov}(Y_i, Y_k) = a'_i \Sigma a_k \quad i, k = 1, 2, \dots, p \quad (5.2)$$

Các thành phần chính là những tổ hợp tuyến tính **không tương quan** $Y_1, Y_2, \dots, Y_p$ mà phương sai của chúng trong (5.1) là lớn nhất có thể.

Thành phần chính thứ nhất là tổ hợp tuyến tính có phương sai lớn nhất. Nghĩa là, nó cực đại hóa $\text{Var}(Y_1) = a'_1 \Sigma a_1$. Rõ ràng rằng $\text{Var}(Y_1) = a'_1 \Sigma a_1$ có thể tăng lên bằng

cách nhân bất kỳ a_1 nào với một hằng số. Để loại bỏ sự bất định này, ta thuận tiện giới hạn sự chú ý vào các véc-tơ hệ số có độ dài đơn vị. Do đó, chúng ta định nghĩa:

- **Thành phần chính thứ nhất** = tổ hợp tuyến tính $a'_1 X$ cực đại hóa

$$\text{Var}(a'_1 X) \quad \text{với điều kiện} \quad a'_1 a_1 = 1$$

- **Thành phần chính thứ hai** = tổ hợp tuyến tính $a'_2 X$ cực đại hóa

$$\text{Var}(a'_2 X) \quad \text{với điều kiện} \quad a'_2 a_2 = 1 \quad \text{và} \quad \text{Cov}(a'_1 X, a'_2 X) = 0$$

- **Thành phần chính thứ i** = tổ hợp tuyến tính $a'_i X$ cực đại hóa

$$\text{Var}(a'_i X) \quad \text{với điều kiện} \quad a'_i a_i = 1 \quad \text{và} \quad \text{Cov}(a'_i X, a'_k X) = 0 \quad \text{với} \quad k < i$$

Định lý 5.1 Cho Σ là ma trận hiệp phương sai của véc-tơ ngẫu nhiên $\mathbf{X}' = [X_1, X_2, \dots, X_p]$. Giả sử Σ có các cặp giá trị riêng và véc-tơ riêng $(\lambda_1, e_1), (\lambda_2, e_2), \dots, (\lambda_p, e_p)$ với $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$. Khi đó **thành phần chính thứ i** được cho bởi:

$$Y_i = e'_i \mathbf{X} = e_{i1} X_1 + e_{i2} X_2 + \dots + e_{ip} X_p, \quad i = 1, 2, \dots, p \quad (5.3)$$

Với các lựa chọn này, ta có:

$$\text{Var}(Y_i) = e'_i \Sigma e_i = \lambda_i, \quad i = 1, 2, \dots, p \quad (5.4)$$

$$\text{Cov}(Y_i, Y_k) = e'_i \Sigma e_k = 0 \quad \text{khi} \quad i \neq k \quad (5.5)$$

Nếu một số λ_i bằng nhau, các lựa chọn véc-tơ hệ số e_i tương ứng và do đó Y_i là không duy nhất.

Định lý 5.2 Từ định lý 5.1, các thành phần chính là không tương quan và có phương sai bằng các giá trị riêng của Σ .

Cho $X' = [X_1, X_2, \dots, X_p]$ có ma trận hiệp phương sai Σ , với các cặp giá trị riêng và véc-tơ riêng $(\lambda_1, e_1), (\lambda_2, e_2), \dots, (\lambda_p, e_p)$ trong đó $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$. Gọi $Y_1 = e'_1 X, Y_2 = e'_2 X, \dots, Y_p = e'_p X$ là các thành phần chính. Khi đó:

$$\sigma_{11} + \sigma_{22} + \cdots + \sigma_{pp} = \sum_{i=1}^p \text{Var}(X_i) = \lambda_1 + \lambda_2 + \cdots + \lambda_p = \sum_{i=1}^p \text{Var}(Y_i) \quad (5.6)$$

Nghĩa là, tổng phương sai của các biến gốc bằng tổng các giá trị riêng, cũng bằng tổng phương sai của các thành phần chính.

Kết quả 5.2 chỉ ra rằng:

$$\text{Tổng phương sai tổng thể} = \sigma_{11} + \sigma_{22} + \cdots + \sigma_{pp} = \lambda_1 + \lambda_2 + \cdots + \lambda_p \quad (5.7)$$

Và do đó, tỷ lệ phương sai tổng thể được giải thích bởi thành phần chính thứ k là:

$$\text{Tỷ lệ phương sai do thành phần thứ } k = \frac{\lambda_k}{\lambda_1 + \lambda_2 + \cdots + \lambda_p}, \quad k = 1, 2, \dots, p \quad (5.8)$$

Nếu phần lớn (ví dụ 80% đến 90%) phương sai tổng thể có thể được quy cho một, hai hoặc ba thành phần đầu tiên, thì các thành phần này có thể "thay thế" p biến gốc mà không làm mất nhiều thông tin.

Mỗi thành phần của véc-tơ hệ số $e'_i = [e_{i1}, \dots, e_{ik}, \dots, e_{ip}]$ cũng cần được xem xét. Độ lớn của e_{ik} đo lường tầm quan trọng của biến thứ k đối với thành phần chính thứ i , không phụ thuộc vào các biến khác. Đặc biệt, e_{ik} tỷ lệ với hệ số tương quan giữa Y_i và X_k .

Định lý 5.3 Nếu $Y_1 = e'_1 X, Y_2 = e'_2 X, \dots, Y_p = e'_p X$ là các thành phần chính thu được từ ma trận hiệp phương sai Σ , thì:

$$\rho_{Y_i, X_k} = \frac{e_{ik} \sqrt{\lambda_i}}{\sqrt{\sigma_{kk}}}, \quad i, k = 1, 2, \dots, p \quad (5.9)$$

là các hệ số tương quan giữa thành phần Y_i và biến X_k . Ở đây $(\lambda_1, e_1), (\lambda_2, e_2), \dots, (\lambda_p, e_p)$ là các cặp giá trị riêng – véc-tơ riêng của Σ .

Mặc dù các hệ số tương quan giữa biến và các thành phần chính thường giúp ích cho việc giải thích các thành phần, chúng chỉ đo lường đóng góp đơn biến của một biến X riêng lẻ đối với thành phần Y . Nghĩa là, chúng không chỉ ra tầm quan trọng của biến X đối với thành phần Y khi có sự hiện diện của các biến X khác. Vì lý do này,

một số nhà thống kê học khuyến nghị chỉ nên sử dụng các hệ số e_{ik} , chứ không phải các hệ số tương quan, để giải thích các thành phần.

Mặc dù các hệ số và các hệ số tương quan có thể dẫn đến các thứ hạng khác nhau như là các thước đo tầm quan trọng của các biến đối với một thành phần nhất định, theo các nghiên cứu trước đó, các thứ hạng này thường không khác biệt đáng kể. Trong thực tế, các biến có hệ số tương đối lớn (theo giá trị tuyệt đối) thường có hệ số tương quan tương đối lớn, do đó hai thước đo tầm quan trọng—thước đo thứ nhất là đa biến và thước đo thứ hai là đơn biến—thường cho kết quả tương tự nhau. Các tài liệu tham khảo đều khuyến nghị nên xem xét cả hệ số lẫn hệ số tương quan để giúp giải thích các thành phần chính.

5.3 Các thành phần chính thu được từ các biến đã được chuẩn hóa

Các thành phần chính cũng có thể được tính cho các biến đã được chuẩn hóa:

$$Z_1 = \frac{(X_1 - \mu_1)}{\sqrt{\sigma_{11}}}, \quad Z_2 = \frac{(X_2 - \mu_2)}{\sqrt{\sigma_{22}}}, \quad \dots, \quad Z_p = \frac{(X_p - \mu_p)}{\sqrt{\sigma_{pp}}}$$

Nếu ta viết dưới dạng ma trận:

$$\mathbf{Z} = (\mathbf{V}^{1/2})^{-1}(\mathbf{X} - \boldsymbol{\mu}) \quad (5.10)$$

trong đó ma trận độ lệch chuẩn đường chéo $\mathbf{V}^{1/2}$ được định nghĩa trong [4]. Rõ ràng, $E(\mathbf{Z}) = \mathbf{0}$ và

$$\text{Cov}(\mathbf{Z}) = (\mathbf{V}^{1/2})^{-1}\Sigma(\mathbf{V}^{1/2})^{-1} = \boldsymbol{\rho} \quad (5.11)$$

Các thành phần chính của $\mathbf{Z}$ có thể thu được từ các véc-tơ riêng của **ma trận tương quan** $\boldsymbol{\rho}$ của $\mathbf{X}$. Tất cả các kết quả trước đây đều áp dụng được, với một số đơn giản hóa, vì phương sai của mỗi Z_i bằng 1. Chúng tôi tiếp tục sử dụng ký hiệu Y_i để chỉ thành phần chính thứ i và $(\lambda_i, \mathbf{e}_i)$ cho cặp giá trị riêng – véc-tơ riêng từ $\boldsymbol{\rho}$ hoặc Σ . Tuy nhiên, $(\lambda_i, \mathbf{e}_i)$ thu được từ Σ nhìn chung không giống với các cặp thu được từ $\boldsymbol{\rho}$.

Định lý 5.4 Thành phần chính thứ i của các biến đã được chuẩn hóa $\mathbf{Z}' = [Z_1, Z_2, \dots, Z_p]$ với $\text{Cov}(\mathbf{Z}) = \boldsymbol{\rho}$ được cho bởi:

$$Y_i = e_i' \mathbf{Z} = e_i' (\mathbf{V}^{1/2})^{-1} (\mathbf{X} - \boldsymbol{\mu}), \quad i = 1, 2, \dots, p$$

Hơn nữa:

$$\sum_{i=1}^p \text{Var}(Y_i) = \sum_{i=1}^p \text{Var}(Z_i) = p \quad (5.12)$$

và

$$\rho_{Y_i, Z_k} = e_{ik} \sqrt{\lambda_i}, \quad i, k = 1, 2, \dots, p$$

Trong trường hợp này, $(\lambda_1, e_1), (\lambda_2, e_2), \dots, (\lambda_p, e_p)$ là các cặp giá trị riêng – véc-tơ riêng của $\boldsymbol{\rho}$, với $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$.

Từ (5.12), ta thấy tổng phương sai tổng thể (của các biến đã chuẩn hóa) đơn giản là p , tức là tổng các phần tử trên đường chéo của ma trận $\boldsymbol{\rho}$. Sử dụng (5.8) với $\mathbf{Z}$ thay cho $\mathbf{X}$, ta tìm được tỷ lệ phương sai tổng thể được giải thích bởi thành phần chính thứ k của $\mathbf{Z}$ là:

$$\left(\text{Tỷ lệ phương sai tổng thể (đã chuẩn hóa) do thành phần chính thứ } k \right) = \frac{\lambda_k}{p}$$

trong đó λ_k là các giá trị riêng của $\boldsymbol{\rho}$, với $k = 1, 2, \dots, p$.

5.4 Tổng hợp biến thiên mẫu bằng các thành phần chính

Bây giờ chúng ta có khung lý thuyết cần thiết để nghiên cứu bài toán tổng hợp biến thiên trong n phép đo trên p biến bằng một vài tổ hợp tuyến tính được lựa chọn một cách khôn ngoan.

Giả sử dữ liệu $x_1, x_2, \dots, x_n$ biểu diễn n lần rút mẫu độc lập từ một tổng thể p -chiều nào đó với véc-tơ trung bình $\boldsymbol{\mu}$ và ma trận hiệp phương sai Σ . Các dữ liệu này cho ta véc-tơ trung bình mẫu $\bar{x}$, ma trận hiệp phương sai mẫu S và ma trận tương quan mẫu R .

Mục tiêu của chúng ta trong phần này là xây dựng các tổ hợp tuyến tính không tương quan của các đặc trưng đo lường nhằm giải thích phần lớn biến thiên trong mẫu. Các tổ hợp không tương quan có phương sai lớn nhất sẽ được gọi là **các thành phần**

chính mẫu (sample principal components).

Nhắc lại rằng n giá trị của bất kỳ tổ hợp tuyến tính nào

$$a'_1 x = a_{11}x_{j1} + a_{12}x_{j2} + \cdots + a_{1p}x_{jp}, \quad j = 1, 2, \dots, n$$

có trung bình mẫu $a'_1 \bar{x}$ và phương sai mẫu $a'_1 S a_1$. Ngoài ra, các cặp giá trị $(a'_1 x_j, a'_2 x_j)$ của hai tổ hợp tuyến tính có hiệp phương sai mẫu $a'_1 S a_2$ [4].

Các thành phần chính mẫu được định nghĩa là những tổ hợp tuyến tính có phương sai mẫu lớn nhất. Cũng như với các đại lượng tổng thể, ta giới hạn các véc-tơ hệ số a_i thỏa mãn $a'_i a_i = 1$. Cụ thể:

- **Thành phần chính mẫu thứ nhất:** là tổ hợp tuyến tính $a'_1 x_j$ cực đại hóa phương sai mẫu của $a'_1 x_j$ với điều kiện $a'_1 a_1 = 1$.
- **Thành phần chính mẫu thứ hai:** là tổ hợp tuyến tính $a'_2 x_j$ cực đại hóa phương sai mẫu của $a'_2 x_j$ với điều kiện $a'_2 a_2 = 1$ và hiệp phương sai mẫu của các cặp $(a'_1 x_j, a'_2 x_j)$ bằng 0.
- Ở bước thứ i , **thành phần chính mẫu thứ i :** là tổ hợp tuyến tính $a'_i x_j$ cực đại hóa phương sai mẫu của $a'_i x_j$ với điều kiện $a'_i a_i = 1$ và hiệp phương sai mẫu với tất cả các thành phần trước đó bằng 0.

Theo (2-51), giá trị lớn nhất chính là giá trị riêng lớn nhất $\hat{\lambda}_1$, đạt được với lựa chọn $a_1 =$ véc-tơ riêng $\hat{e}_1$ của S . Các lựa chọn tiếp theo của a_i cực đại hóa (8-19) với điều kiện $0 = a_i^T S e_k = a_i^T \lambda_k e_k$, hay a_i vuông góc với e_k . Do đó, như trong chứng minh của các Kết quả 5.1–5.3, chúng ta thu được các kết quả sau đây liên quan đến các thành phần chính mẫu:

Nếu $S = \{s_{ik}\}$ là ma trận hiệp phương sai mẫu $p \times p$ với các cặp giá trị riêng – véc-tơ riêng $(\hat{\lambda}_1, \hat{e}_1), (\hat{\lambda}_2, \hat{e}_2), \dots, (\hat{\lambda}_p, \hat{e}_p)$, thì thành phần chính mẫu thứ i được cho bởi:

$$\hat{y}_i = \hat{e}_i^T x = \hat{e}_{i1}x_1 + \hat{e}_{i2}x_2 + \cdots + \hat{e}_{ip}x_p, \quad i = 1, 2, \dots, p \quad (5.13)$$

trong đó $\hat{\lambda}_1 \geq \hat{\lambda}_2 \geq \cdots \geq \hat{\lambda}_p \geq 0$ và x là bất kỳ quan sát nào trên các biến $X_1, X_2, \dots, X_p$.

Ngoài ra:

$$\begin{aligned}\text{Phương sai mẫu}(\hat{y}_k) &= \hat{\lambda}_k, \quad k = 1, 2, \dots, p \\ \text{Hiệp phương sai mẫu}(\hat{y}_i, \hat{y}_k) &= 0, \quad i \neq k\end{aligned}\tag{5.14}$$

Hơn nữa:

$$\text{Tổng phương sai mẫu} = \sum_{i=1}^p s_{ii} = \hat{\lambda}_1 + \hat{\lambda}_2 + \dots + \hat{\lambda}_p$$

và

$$r_{\hat{y}_i, x_k} = \frac{\hat{e}_{ik} \sqrt{\hat{\lambda}_i}}{\sqrt{s_{kk}}}, \quad i, k = 1, 2, \dots, p$$

là các hệ số tương quan mẫu giữa thành phần chính thứ i và biến thứ k .

Chúng ta sẽ ký hiệu các thành phần chính mẫu là $\hat{y}_1, \hat{y}_2, \dots, \hat{y}_p$, bất kể chúng thu được từ S hay $\mathbf{R}$. Các thành phần được xây dựng từ S và $\mathbf{R}$ nhìn chung là không giống nhau, nhưng ngữ cảnh sẽ làm rõ ma trận nào đang được sử dụng, và việc sử dụng một ký hiệu duy nhất $\hat{y}_i$ là thuận tiện. Cũng thuận tiện khi gán nhãn các véc-tơ hệ số thành phần là $\hat{e}_i$ và phương sai thành phần là λ_i cho cả hai trường hợp.

Các quan sát $\mathbf{x}_j$ thường được "làm lệch tâm" (centered) bằng cách trừ đi $\bar{\mathbf{x}}$. Việc này không ảnh hưởng đến ma trận hiệp phương sai mẫu S và cho thành phần chính thứ i :

$$\hat{y}_i = \hat{e}_i^T (\mathbf{x} - \bar{\mathbf{x}}), \quad i = 1, 2, \dots, p\tag{5.15}$$

cho bất kỳ véc-tơ quan sát nào $\mathbf{x}$. Nếu xét các giá trị của thành phần thứ i :

$$\hat{y}_{ji} = \hat{e}_i^T (\mathbf{x}_j - \bar{\mathbf{x}}), \quad j = 1, 2, \dots, n\tag{5.16}$$

được tạo ra bằng cách thay thế mỗi quan sát $\mathbf{x}_j$ cho $\mathbf{x}$ tùy ý trong (5.15), thì:

$$\bar{\mathbf{y}}_i = \frac{1}{n} \sum_{j=1}^n \hat{e}_i^T (\mathbf{x}_j - \bar{\mathbf{x}}) = \frac{1}{n} \hat{e}_i^T \left(\sum_{j=1}^n (\mathbf{x}_j - \bar{\mathbf{x}}) \right) = \frac{1}{n} \hat{e}_i^T \mathbf{0} = 0\tag{5.17}$$

Nghĩa là, trung bình mẫu của mỗi thành phần chính bằng 0. Các phương sai mẫu vẫn được cho bởi các λ_i như trong (5.14).

Chương 6

Cài đặt thử nghiệm

Sau khi hoàn thành quy trình tiền xử lý dữ liệu bao gồm xử lý dữ liệu thiếu, chuẩn hóa đặc trưng, loại bỏ ngoại lai và tối ưu hóa tập biến đầu vào, nghiên cứu tiến hành áp dụng mô hình PCA nhằm giảm số chiều dữ liệu và đánh giá khả năng bảo toàn thông tin của tập dữ liệu ban đầu. Trong PCA, một trong những vấn đề quan trọng nhất là quyết định cần giữ lại bao nhiêu thành phần chính để biểu diễn dữ liệu. Việc chọn quá ít thành phần có thể làm mất đi thông tin quan trọng, trong khi chọn quá nhiều thành phần sẽ làm giảm hiệu quả của việc giảm chiều dữ liệu.

Phương pháp phổ biến nhất để giải quyết vấn đề này là dựa vào **phương sai tích lũy** (cumulative variance). Cụ thể, sau khi thực hiện phân tích trị riêng trên ma trận hiệp phương sai của dữ liệu, ta thu được các trị riêng $\lambda_1, \lambda_2, \dots, \lambda_p$ được sắp xếp theo thứ tự giảm dần, với $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$ và p là số chiều ban đầu của dữ liệu. Mỗi trị riêng λ_k đo lường lượng phương sai mà thành phần chính thứ k giải thích được.

Tổng phương sai của toàn bộ dữ liệu chính là tổng của tất cả các trị riêng:

$$\text{Tổng phương sai} = \sum_{j=1}^p \lambda_j$$

Nếu ta chọn m thành phần chính đầu tiên, thì lượng phương sai mà chúng giải thích được là:

$$\text{Phương sai giữ lại} = \sum_{k=1}^m \lambda_k$$

Do đó, tỉ lệ phương sai được bảo toàn khi chọn m thành phần là:

$$R(m) = \frac{\sum_{k=1}^m \lambda_k}{\sum_{j=1}^p \lambda_j}$$

Rõ ràng $R(m)$ là một hàm không giảm theo m , với $R(0) = 0$ và $R(p) = 1$. Thuật toán lựa chọn số thành phần dựa trên một **ngưỡng phương sai** θ (thường được chọn là 0.9 hoặc 0.95 tương ứng với giữ lại 90% hoặc 95% thông tin). Số lượng thành phần m được chọn là số nguyên nhỏ nhất thỏa mãn điều kiện:

$$\boxed{\frac{\sum_{k=1}^m \lambda_k}{\sum_{j=1}^p \lambda_j} \geq \theta}$$

Nói cách khác, $m = \min \{m \in \{1, 2, \dots, p\} \mid R(m) \geq \theta\}$. Ví dụ, giả sử với một bộ dữ liệu có $p = 5$ chiều, ta tính được các trị riêng và phương sai tích lũy như sau:

k	λ_k	Tỉ lệ riêng ($\lambda_k / \sum \lambda_j$)	Tỉ lệ tích lũy $R(k)$
1	3.50	0.583	0.583
2	1.80	0.300	0.883
3	0.40	0.067	0.950
4	0.20	0.033	0.983
5	0.10	0.017	1.000

Nếu đặt ngưỡng $\theta = 0.9$, ta thấy $R(2) = 0.883 < 0.9$ (chưa đạt) và $R(3) = 0.950 \geq 0.9$ (đã đạt). Vậy $m = 3$ thành phần được chọn, giữ lại 95% phương sai của dữ liệu gốc.

Tóm lại, phương trình trung tâm của việc lựa chọn số thành phần trong PCA là bất đẳng thức:

$$\frac{\sum_{k=1}^m \lambda_k}{\sum_{j=1}^p \lambda_j} \geq \theta$$

và m được chọn là giá trị nhỏ nhất thỏa mãn điều kiện này.

Sau khi đã thực hiện phân tích thành phần chính (PCA) để giảm số chiều của dữ liệu, mô hình hồi quy logistic (Logistic Regression) được sử dụng để đánh giá hiệu suất phân loại dựa trên độ chính xác (accuracy). Quy trình xử lý được thực hiện như sau. Đầu tiên, PCA chỉ được khớp (fit) trên tập huấn luyện (training set) để học các tham số như véc-tơ trung bình và ma trận xoay. Sau đó, cả tập huấn luyện và tập kiểm tra (test set) đều được biến đổi (transform) sang không gian thành phần chính bằng chính

các tham số đã học từ tập huấn luyện. Việc này đảm bảo không có sự rò rỉ thông tin từ tập kiểm tra sang quá trình huấn luyện. Mô hình hồi quy logistic tiếp theo được huấn luyện trên tập huấn luyện đã qua PCA, và sau đó được sử dụng để dự đoán nhãn cho cả tập huấn luyện và tập kiểm tra. Độ chính xác (accuracy) được tính toán trên cả hai tập, cho phép đánh giá khả năng tổng quát hóa của mô hình và phát hiện hiện tượng overfitting (khi độ chính xác trên tập huấn luyện cao hơn nhiều so với tập kiểm tra). Kết quả độ chính xác của mô hình sử dụng PCA sau đó được so sánh với độ chính xác của mô hình huấn luyện trên dữ liệu gốc (không qua PCA) để đánh giá hiệu quả của việc giảm chiều.

6.1 Tập dữ liệu béo phì

Nhóm chọn tham số $\theta = 0.9$. Kết quả thực nghiệm cho thấy bộ dữ liệu nghiên cứu ban đầu gồm 16 biến đầu vào, trong đó mô hình PCA lựa chọn 12 thành phần chính để biểu diễn dữ liệu sau giảm chiều. Với số lượng thành phần này, tỷ lệ phương sai được giữ lại đạt khoảng 90,33%, cho thấy phần lớn thông tin quan trọng của dữ liệu gốc vẫn được bảo toàn mặc dù số chiều dữ liệu đã giảm đáng kể.

```
Eigenvalues:
[2.60450109 1.86468222 1.52941424 1.35685339 1.12538071 1.06645685
 0.98163947 0.87104835 0.8192875 0.78813199 0.75893488 0.68603821
 0.6010778 0.40064148 0.32819138 0.21772047]

Explained Variance Ratio:
[0.16278132 0.11654264 0.09558839 0.08480334 0.07033629 0.06665355
 0.06135247 0.05444052 0.05120547 0.04925825 0.04743343 0.04287739
 0.03756736 0.02504009 0.02051196 0.01360753]


Cumulative Variance:
[0.16278132 0.27932396 0.37491235 0.45971568 0.53005198 0.59670553
 0.658058 0.71249852 0.76370399 0.81296224 0.86039567 0.90327306
 0.94084042 0.96588051 0.98639247 1.
 ]
```

Hình 6.1: Bảng tóm tắt PCA

Các giá trị riêng (eigenvalues) của những thành phần chính đầu tiên tương đối lớn, cụ thể thành phần chính thứ nhất đạt khoảng 2,60, thành phần thứ hai đạt 1,86, và thành phần thứ ba đạt 1,53, phản ánh mức độ đóng góp đáng kể của các thành phần này vào tổng biến thiên của dữ liệu. Kết quả phân tích tỷ lệ phương sai giải

thích (Explained variance ratio) cho thấy thành phần chính thứ nhất giải thích khoảng 16,28% phương sai dữ liệu, thành phần thứ hai giải thích 11,65%, trong khi các thành phần tiếp theo có mức đóng góp giảm dần. Điều này phù hợp với nguyên lý của PCA khi phần lớn thông tin của dữ liệu thường tập trung ở một số thành phần đầu tiên.

Phân tích phương sai tích lũy (Cumulative variance) cho thấy lượng thông tin được giữ lại tăng dần theo số lượng thành phần chính được lựa chọn. Cụ thể, 6 thành phần chính đầu tiên có khả năng giải thích khoảng 59,67% tổng biến thiên của dữ liệu, cho thấy hơn một nửa thông tin của tập dữ liệu ban đầu đã được tóm tắt chỉ thông qua một số lượng nhỏ thành phần. Khi mở rộng lên 10 thành phần chính, tỷ lệ phương sai tích lũy tăng lên khoảng 81,30%, phản ánh phần lớn cấu trúc và đặc điểm của dữ liệu đã được bảo toàn. Đối với 12 thành phần chính, mô hình đạt mức giải thích khoảng 90,33% tổng phương sai, đồng nghĩa với việc gần như toàn bộ thông tin quan trọng của dữ liệu ban đầu vẫn được duy trì sau quá trình giảm chiều. Cuối cùng, khi sử dụng đầy đủ 16 thành phần, phương sai tích lũy đạt 100%, tương ứng với việc toàn bộ thông tin của tập dữ liệu gốc được giữ nguyên, xem ở Hình 6.2.



Hình 6.2: Enter Caption

Kết quả này cho thấy phần lớn biến thiên của dữ liệu tập trung ở một số lượng tương đối nhỏ các thành phần chính đầu tiên. Do đó, việc lựa chọn 12 thành phần chính thay vì giữ nguyên toàn bộ 16 biến ban đầu giúp giảm độ phức tạp của dữ liệu

khoảng 25%, trong khi vẫn bảo toàn được hơn 90% thông tin tổng thể. Điều này phản ánh hiệu quả của PCA trong việc loại bỏ thông tin dư thừa, giảm hiện tượng tương quan giữa các biến và tối ưu hóa dữ liệu đầu vào cho các mô hình phân tích hoặc dự báo tiếp theo. Trong bối cảnh dữ liệu y tế và chăm sóc sức khỏe, khả năng giảm chiều nhưng vẫn duy trì phần lớn thông tin có ý nghĩa quan trọng đối với việc tăng tốc độ xử lý dữ liệu, giảm chi phí tính toán và hỗ trợ xây dựng các hệ thống phân tích có độ chính xác cao hơn.


```
original_dimensions: 16
selected_components: 12
variance_retained: 0.9032730552044889
dimension_reduction_ratio: 0.25
reconstruction_error: 0.09668112435742726
condition_number: 11.962591907544642
kaiser_components: 6
```

Hình 6.3: Metrics PCA

Bên cạnh đó, sai số tái tạo dữ liệu (`reconstruction_error`) thu được ở mức khoảng 0,097, phản ánh khả năng biểu diễn lại dữ liệu gốc của mô hình PCA tương đối tốt sau quá trình giảm chiều. Giá trị `condition_number` = 11,97 cho thấy dữ liệu chưa xuất hiện mức độ phụ thuộc tuyến tính nghiêm trọng giữa các biến, góp phần đảm bảo tính ổn định của mô hình trong quá trình xử lý. Theo tiêu chuẩn Kaiser, số lượng thành phần chính có giá trị riêng lớn hơn 1 là 6 thành phần, tuy nhiên nghiên cứu lựa chọn giữ lại 12 thành phần nhằm đảm bảo tỷ lệ bảo toàn thông tin cao hơn trong bối cảnh dữ liệu, nơi việc mất thông tin có thể ảnh hưởng đến chất lượng phân tích và khả năng hỗ trợ ra quyết định.

Kết quả thực nghiệm được trình bày trong Bảng 4.1 cho thấy sự khác biệt rõ rệt giữa hai phương pháp. Cụ thể, mô hình hồi quy logistic không sử dụng PCA đạt độ chính xác trên tập huấn luyện là 88,0% và trên tập kiểm tra là 83,0%. Chênh lệch giữa hai tập là 5 điểm phần trăm, cho thấy mô hình có xu hướng học quá chi tiết các đặc trưng của tập huấn luyện, dẫn đến hiện tượng *overfitting*. Nguyên nhân là do số chiều của dữ liệu gốc lớn, chứa nhiều thông tin dư thừa và nhiễu, khiến mô hình khó tổng quát hóa trên dữ liệu mới.

Trong khi đó, mô hình có sử dụng PCA đạt độ chính xác trên tập huấn luyện là 82,0% và trên tập kiểm tra là 81,0%, với mức chênh lệch chỉ 1 điểm phần trăm. Mặc



Hình 6.4: PCA vs non-PCA với Logistic Regression của tập dữ liệu béo phì

dù độ chính xác tuyệt đối trên tập kiểm tra của mô hình có PCA thấp hơn 2% so với mô hình không PCA (81% so với 83%), nhưng mô hình này thể hiện khả năng tổng quát hóa vượt trội nhờ vào việc giảm số chiều thành công. PCA đã loại bỏ các thành phần có phương sai thấp (tức là các đặc trưng ít thông tin và nhiễu), giúp mô hình tập trung vào những đặc trưng quan trọng nhất. Kết quả là mô hình ít bị overfitting hơn, thể hiện qua khoảng cách nhỏ giữa độ chính xác trên tập huấn luyện và tập kiểm tra.

Từ những phân tích trên, có thể kết luận rằng mặc dù việc áp dụng PCA có thể làm giảm nhẹ độ chính xác tuyệt đối của mô hình, nhưng nó mang lại lợi ích quan trọng trong việc cải thiện khả năng tổng quát hóa và giảm overfitting. Đây là một sự đánh đổi hợp lý, đặc biệt trong các bài toán có số chiều lớn hoặc khi ưu tiên tính ổn định của mô hình trên dữ liệu mới hơn là độ chính xác tối đa trên tập huấn luyện.


Nhìn chung, kết quả thực nghiệm cho thấy phương pháp PCA có khả năng giảm đáng kể độ phức tạp của dữ liệu nhiều chiều nhưng vẫn duy trì được phần lớn thông tin quan trọng của tập dữ liệu ban đầu. Điều này chứng minh PCA là một phương pháp phù hợp để hỗ trợ xử lý dữ liệu y tế, góp phần cải thiện hiệu quả phân tích dữ liệu, hạn chế hiện tượng đa cộng tuyến và tạo tiền đề cho việc xây dựng các mô hình dự báo hoặc hệ thống hỗ trợ quyết định trong lĩnh vực chăm sóc sức khỏe.

6.2 Tập MNIST

Đối với tập dữ liệu MNIST, PCA được áp dụng với ngưỡng phương sai tích lũy là 90%. Kết quả cho thấy số thành phần chính được chọn là 109, giảm đáng kể từ 784 chiều ban đầu xuống còn 109 chiều, tương ứng với mức giảm khoảng 86%.

Phương sai của 10 thành phần chính đầu tiên lần lượt là 34.56, 25.56, 21.24, 17.54, 14.81, 13.04, 11.43, 8.86, 8.54 và 7.83. Tỷ lệ phương sai được giải thích bởi thành phần chính thứ nhất là 9.53%, thành phần thứ hai đóng góp 7.05%, thành phần thứ ba đóng góp 5.86%, và 7 thành phần tiếp theo đóng góp lần lượt 4.83%, 4.08%, 3.59%, 3.15%, 2.44%, 2.35% và 2.16%. Tổng cộng, mười thành phần đầu tiên giải thích được khoảng 45.05% tổng phương sai của dữ liệu.

Tỷ lệ phương sai tích lũy cho thấy để đạt được 90% phương sai tổng thể, cần sử dụng 109 thành phần chính. Điều này cho thấy dữ liệu MNIST có cấu trúc phức tạp, đòi hỏi nhiều thành phần hơn so với bộ dữ liệu béo phì để giải thích hầu hết sự biến thiên của dữ liệu. Nguyên nhân là do MNIST là dữ liệu ảnh với 784 pixel, mỗi pixel



Hình 6.5: PCA vs non-PCA với Logistic Regression của tập MNIST

mang một lượng thông tin nhất định và các pixel có tương quan phức tạp với nhau.

Bảng dưới đây trình bày tóm tắt kết quả PCA trên tập dữ liệu MNIST:

Bảng 6.1: Kết quả PCA trên tập dữ liệu MNIST

Chỉ tiêu	Giá trị
Số chiều ban đầu	784
Số thành phần chính (90% phương sai)	109
Mức độ giảm chiều	86.1%
Phương sai thành phần thứ nhất	34.56
Phương sai thành phần thứ hai	25.56
Phương sai thành phần thứ ba	21.24
Tỷ lệ phương sai 10 thành phần đầu	45.05%

Kết quả thực nghiệm trên tập dữ liệu MNIST cho thấy mô hình hồi quy logistic không sử dụng PCA đạt độ chính xác trên tập huấn luyện là 98,0% và trên tập kiểm tra là 90,6%, với chênh lệch 7,4 điểm phần trăm. Trong khi đó, mô hình có sử dụng PCA đạt độ chính xác trên tập huấn luyện là 96,7% và trên tập kiểm tra là 92,5%, với chênh lệch chỉ 4,2 điểm phần trăm. Mặc dù độ chính xác trên tập huấn luyện của mô

hình không PCA cao hơn, nhưng mô hình có PCA lại đạt độ chính xác trên tập kiểm tra cao hơn (92,5% so với 90,6%) và có khoảng cách giữa train và test nhỏ hơn, cho thấy khả năng tổng quát hóa tốt hơn, tương tự như kết quả đã quan sát được trên tập dữ liệu béo phì. Như vậy, việc áp dụng PCA không chỉ giúp giảm số chiều dữ liệu đáng kể (từ 784 xuống còn 109 thành phần, tức giảm khoảng 86%), mà còn cải thiện hiệu suất phân loại trên tập kiểm tra, đồng thời giảm hiện tượng overfitting.


6.3 Tập CIFAR-10

Đối với tập dữ liệu CIFAR-10, PCA được áp dụng với ngưỡng phương sai tích lũy là 90%. Kết quả cho thấy số thành phần chính được chọn là 161, giảm đáng kể từ 3072 chiều ban đầu xuống còn 161 chiều, tương ứng với mức giảm khoảng 94,8%. Mười thành phần chính đầu tiên có phương sai lần lượt là 30,77%, 12,24%, 7,38%, 3,93%, 3,13%, 2,93%, 2,86%, 2,11%, 2,02% và 1,48%. Tổng cộng, mười thành phần đầu tiên giải thích được khoảng 68,85% tổng phương sai của dữ liệu.

Kết quả thực nghiệm trên tập dữ liệu CIFAR-10 cho thấy một hiện tượng rất khác biệt so với hai tập dữ liệu trước. Mô hình hồi quy logistic không sử dụng PCA đạt độ chính xác trên tập huấn luyện là 99,5% nhưng chỉ đạt 28,5% trên tập kiểm tra, với chênh lệch lên tới 71 điểm phần trăm, cho thấy hiện tượng overfitting rất nghiêm trọng. Nguyên nhân là do tập dữ liệu CIFAR-10 có số chiều rất lớn (3072 đặc trưng) so với số lượng mẫu huấn luyện, khiến mô hình học quá chi tiết các đặc trưng nhiễu trong dữ liệu huấn luyện.

Trong khi đó, mô hình có sử dụng PCA đạt độ chính xác trên tập huấn luyện là 46,5% và trên tập kiểm tra là 37,0%, với chênh lệch chỉ 9,5 điểm phần trăm. Mặc dù độ chính xác tuyệt đối của mô hình có PCA thấp hơn đáng kể so với mô hình không PCA trên tập huấn luyện, nhưng trên tập kiểm tra, mô hình có PCA lại cho kết quả tốt hơn (37,0% so với 28,5%). Điều này chứng tỏ PCA đã giúp giảm overfitting một cách hiệu quả, nhờ việc giảm số chiều từ 3072 xuống còn 161 thành phần (giảm khoảng 94,8%) và chỉ giữ lại những thông tin quan trọng nhất.

Bảng dưới đây trình bày tóm tắt kết quả PCA và đánh giá mô hình trên tập dữ liệu CIFAR-10:



Hình 6.6: PCA vs non-PCA với Logistic Regression của tập CIFAR-10

Bảng 6.2: Kết quả PCA và đánh giá mô hình trên tập dữ liệu CIFAR-10

Chỉ tiêu	Giá trị
Số chiều ban đầu	3072
Số thành phần chính (90% phương sai)	161
Mức độ giảm chiều	94,8%
Phương sai PC1	30,77%
Phương sai PC2	12,24%
Phương sai PC3	7,38%
Tổng phương sai 10 PC đầu	68,85%

Hạn chế và kết luận

Mặc dù nghiên cứu đã đạt được một số kết quả khả quan, vẫn còn tồn tại một số hạn chế cần được ghi nhận. Thứ nhất, pipeline xử lý dữ liệu hiện tại chỉ áp dụng label encoding cho các biến phân loại có nhiều giá trị như CAEC, CALC và MTRANS, thay vì sử dụng one-hot encoding. Điều này có thể tạo ra mối quan hệ thứ tự giả tạo giữa các danh mục, ảnh hưởng đến kết quả của mô hình, đặc biệt là đối với các thuật toán dạng hồi quy tuyến tính. Thứ hai, việc phát hiện ngoại lai bằng khoảng cách Mahalanobis phụ thuộc vào giả định phân phối chuẩn đa biến của dữ liệu. Trong thực tế, dữ liệu về béo phì và đặc biệt là dữ liệu ảnh như MNIST và CIFAR-10 không hoàn toàn tuân theo phân phối chuẩn, do đó kết quả phát hiện ngoại lai có thể chưa thực sự chính xác. Thứ ba, nghiên cứu chỉ sử dụng mô hình hồi quy logistic để đánh giá hiệu suất sau PCA. Việc chỉ sử dụng một mô hình đơn lẻ chưa đủ để khẳng định tính hiệu quả của PCA trên mọi loại mô hình học máy. Các mô hình phức tạp hơn như Random Forest, SVM hay mạng nơ-ron sâu có thể cho kết quả khác biệt. Thứ tư, đối với tập dữ liệu CIFAR-10, độ chính xác của mô hình sau PCA chỉ đạt 37,0%, một con số còn khiêm tốn. Điều này cho thấy việc áp dụng PCA đơn thuần trên dữ liệu ảnh màu phức tạp có thể chưa đủ, cần kết hợp với các kỹ thuật trích xuất đặc trưng tiên tiến hơn như CNN. Cuối cùng, nghiên cứu mới chỉ dừng lại ở việc đánh giá trên ba bộ dữ liệu cụ thể. Để có kết luận tổng quát hơn, cần thử nghiệm trên nhiều bộ dữ liệu đa dạng khác với các đặc điểm khác nhau về số chiều, kích thước mẫu và bản chất dữ liệu.

Nghiên cứu này đã xây dựng một pipeline xử lý dữ liệu hoàn chỉnh cho các bài toán phân loại, bao gồm các bước xử lý giá trị thiếu, mã hóa biến phân loại, loại bỏ biến có phương sai thấp, chuẩn hóa dữ liệu và phát hiện ngoại lai bằng khoảng cách Mahalanobis. Pipeline đảm bảo tính nhất quán giữa tập huấn luyện và tập kiểm tra, tuân thủ nguyên tắc không để rò rỉ thông tin. Việc áp dụng PCA sau pipeline cho thấy hiệu quả rõ rệt trong việc giảm số chiều dữ liệu. Trên tập dữ liệu béo phì, PCA giảm

từ 16 xuống 9 thành phần; trên MNIST, giảm từ 784 xuống 109 thành phần (giảm 86%); trên CIFAR-10, giảm từ 3072 xuống 161 thành phần (giảm gần 95%). Kết quả này khẳng định PCA là công cụ mạnh mẽ để giảm chiều dữ liệu.

Về hiệu suất phân loại, PCA giúp cải thiện khả năng tổng quát hóa của mô hình. Trên tập béo phì, mô hình có PCA có độ chênh lệch giữa train và test chỉ 1% so với 5% của mô hình không PCA. Trên MNIST, mô hình có PCA đạt độ chính xác trên tập kiểm tra cao hơn (92,5% so với 90,6%) và chênh lệch nhỏ hơn. Đặc biệt trên CIFAR-10, mặc dù độ chính xác tuyệt đối còn thấp, PCA đã giúp giảm overfitting nghiêm trọng từ chênh lệch 71% xuống còn 9,5%, đồng thời cải thiện độ chính xác trên tập kiểm tra từ 28,5% lên 37,0%. Tóm lại, PCA là một kỹ thuật giảm chiều hiệu quả, đặc biệt hữu ích khi làm việc với dữ liệu có số chiều lớn. Việc kết hợp PCA với pipeline xử lý dữ liệu đúng cách không chỉ giúp giảm chi phí tính toán mà còn cải thiện khả năng tổng quát hóa của mô hình, giảm hiện tượng overfitting. Tuy nhiên, hiệu quả của PCA phụ thuộc nhiều vào đặc điểm của từng bộ dữ liệu và cần được xem xét cẩn trọng trong từng bài toán cụ thể.

Tài liệu tham khảo

- [1] World Health Organization, *Obesity and overweight (2025, December 8)*, <https://www.who.int/news-room/fact-sheets/detail/obesity-and-overweight>
- [2] Fabio Mendoza Palechor, Alexis De la Hoz Manotas, *Dataset for estimation of obesity levels based on eating habits and physical condition in individuals from Colombia, Peru and Mexico*, <https://doi.org/10.1016/j.dib.2019.104344>
- [3] N. V. Chawla, K. W. Bowyer, L. O. Hall, W. P. Kegelmeyer, *SMOTE: Synthetic Minority Over-sampling Technique*, <https://arxiv.org/pdf/1106.1813>
- [4] Richard A. Johnson, Dean W. Wichern, *Applied Multivariate Statistical Analysis 6th edition*.

Phụ lục minh bạch AI

Công cụ AI	Dùng cho việc gì	Phần đầu ra được giữ lại	Cách kiểm chứng
ChatGPT	Định dạng, cấu trúc văn bản báo cáo	Các đoạn nối giữa các phần trong báo cáo	Đối chiếu và chỉnh sửa thủ công
ChatGPT	Gợi ý viết hàm của mô hình PCA trong lập trình	Giữ lại các đoạn mã	Kết quả in xấp xỉ với hàm có sẵn trong thư viện
ChatGPT	Làm sạch các đoạn mã lập trình	Giữ lại các đoạn mã	Code dễ nhìn hơn